워크샵 목표



생성형 AI
이해



생성형 AI의
약점



하네스
엔지니어링



신뢰성 높은
AI 워크플로우 구성

WeDataLab

하네스 엔지니어링

- 생성형 AI 개요

2026년 10월

© Copyrights 2026. Wedatalab All Rights Reserved.

목차

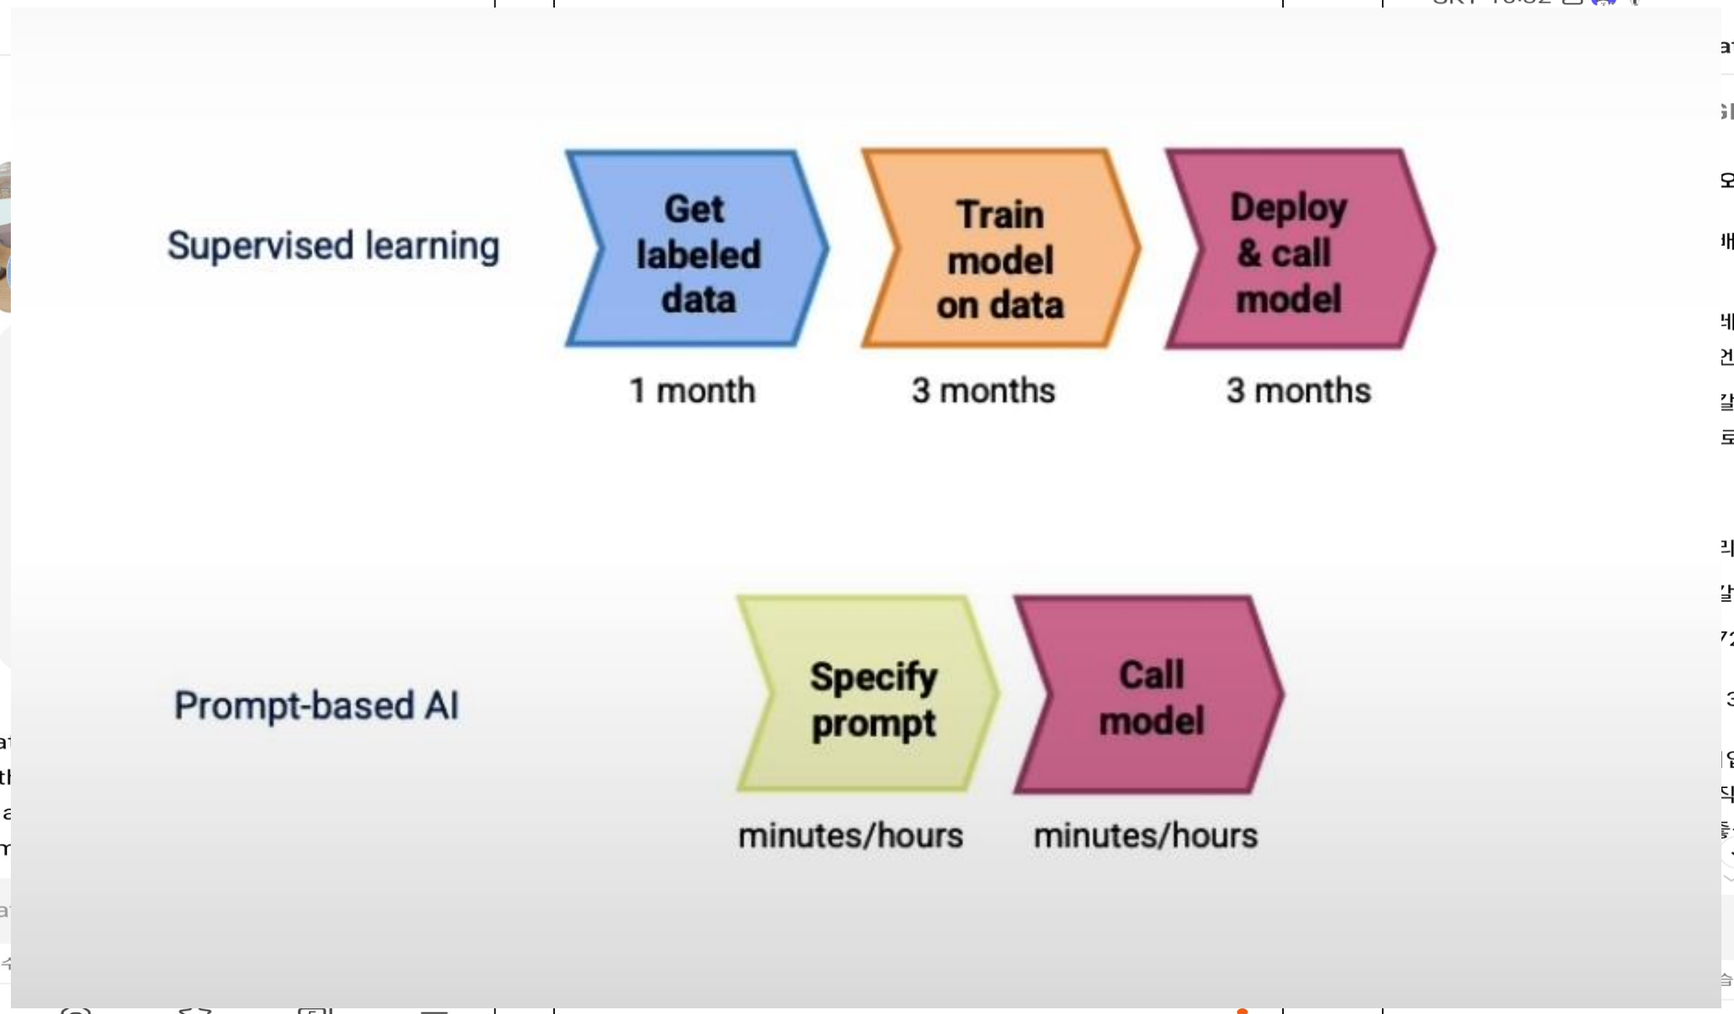
- AI, 사회 기반 시설
- 주요 기술과 특성
- 요약

AI, 사회 기반 시설

앤드류 응 교수 좌담회

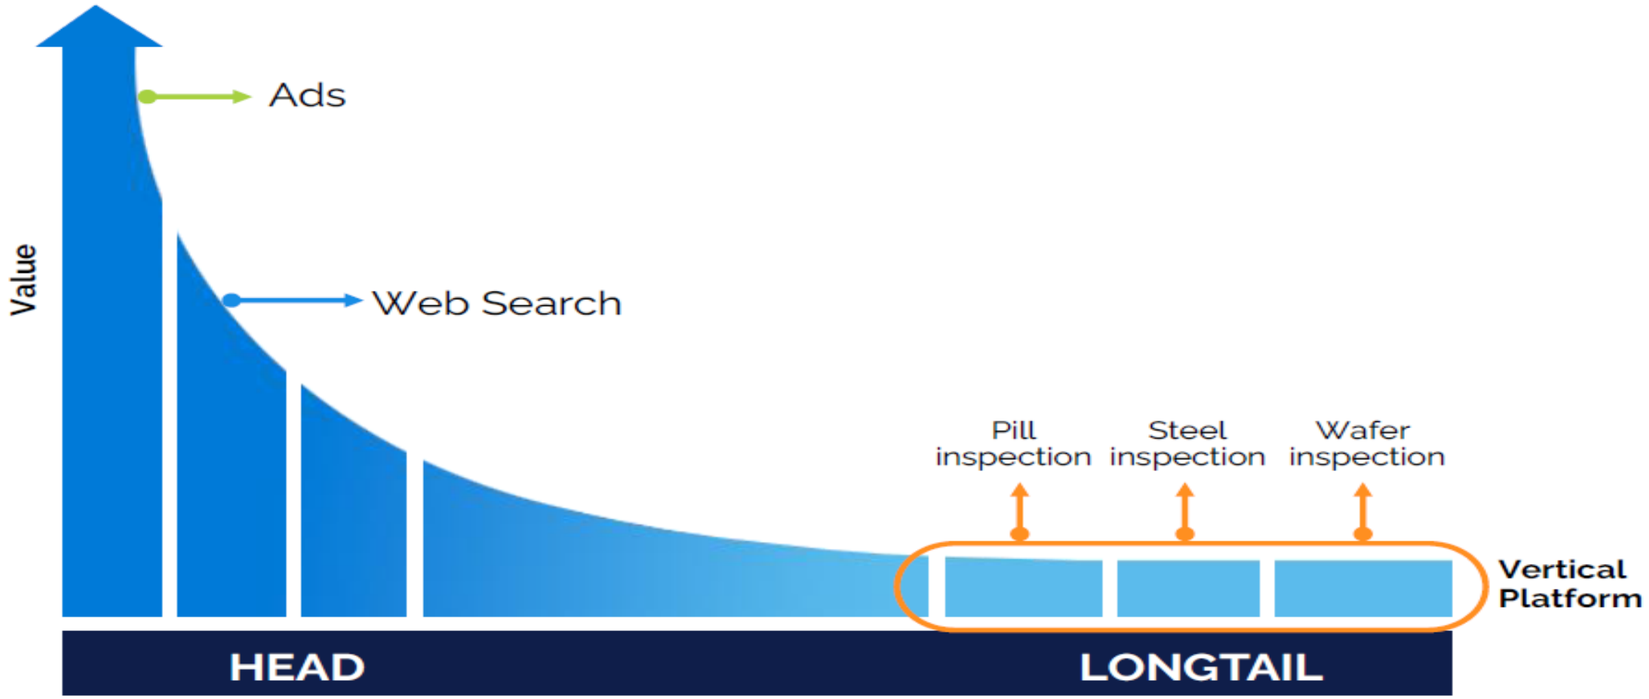

AI Talk
with Andrew Ng
Keynote, Fireside Chat & Networking
KBS 별관 공개홀 | 온•오프라인 동시 진행
2023.07.21.8PM
과학기술정보통신부
nipa 정보통신산업진흥원

머신러닝 훈련은 필요한가?



AI 적용의 Long Tail

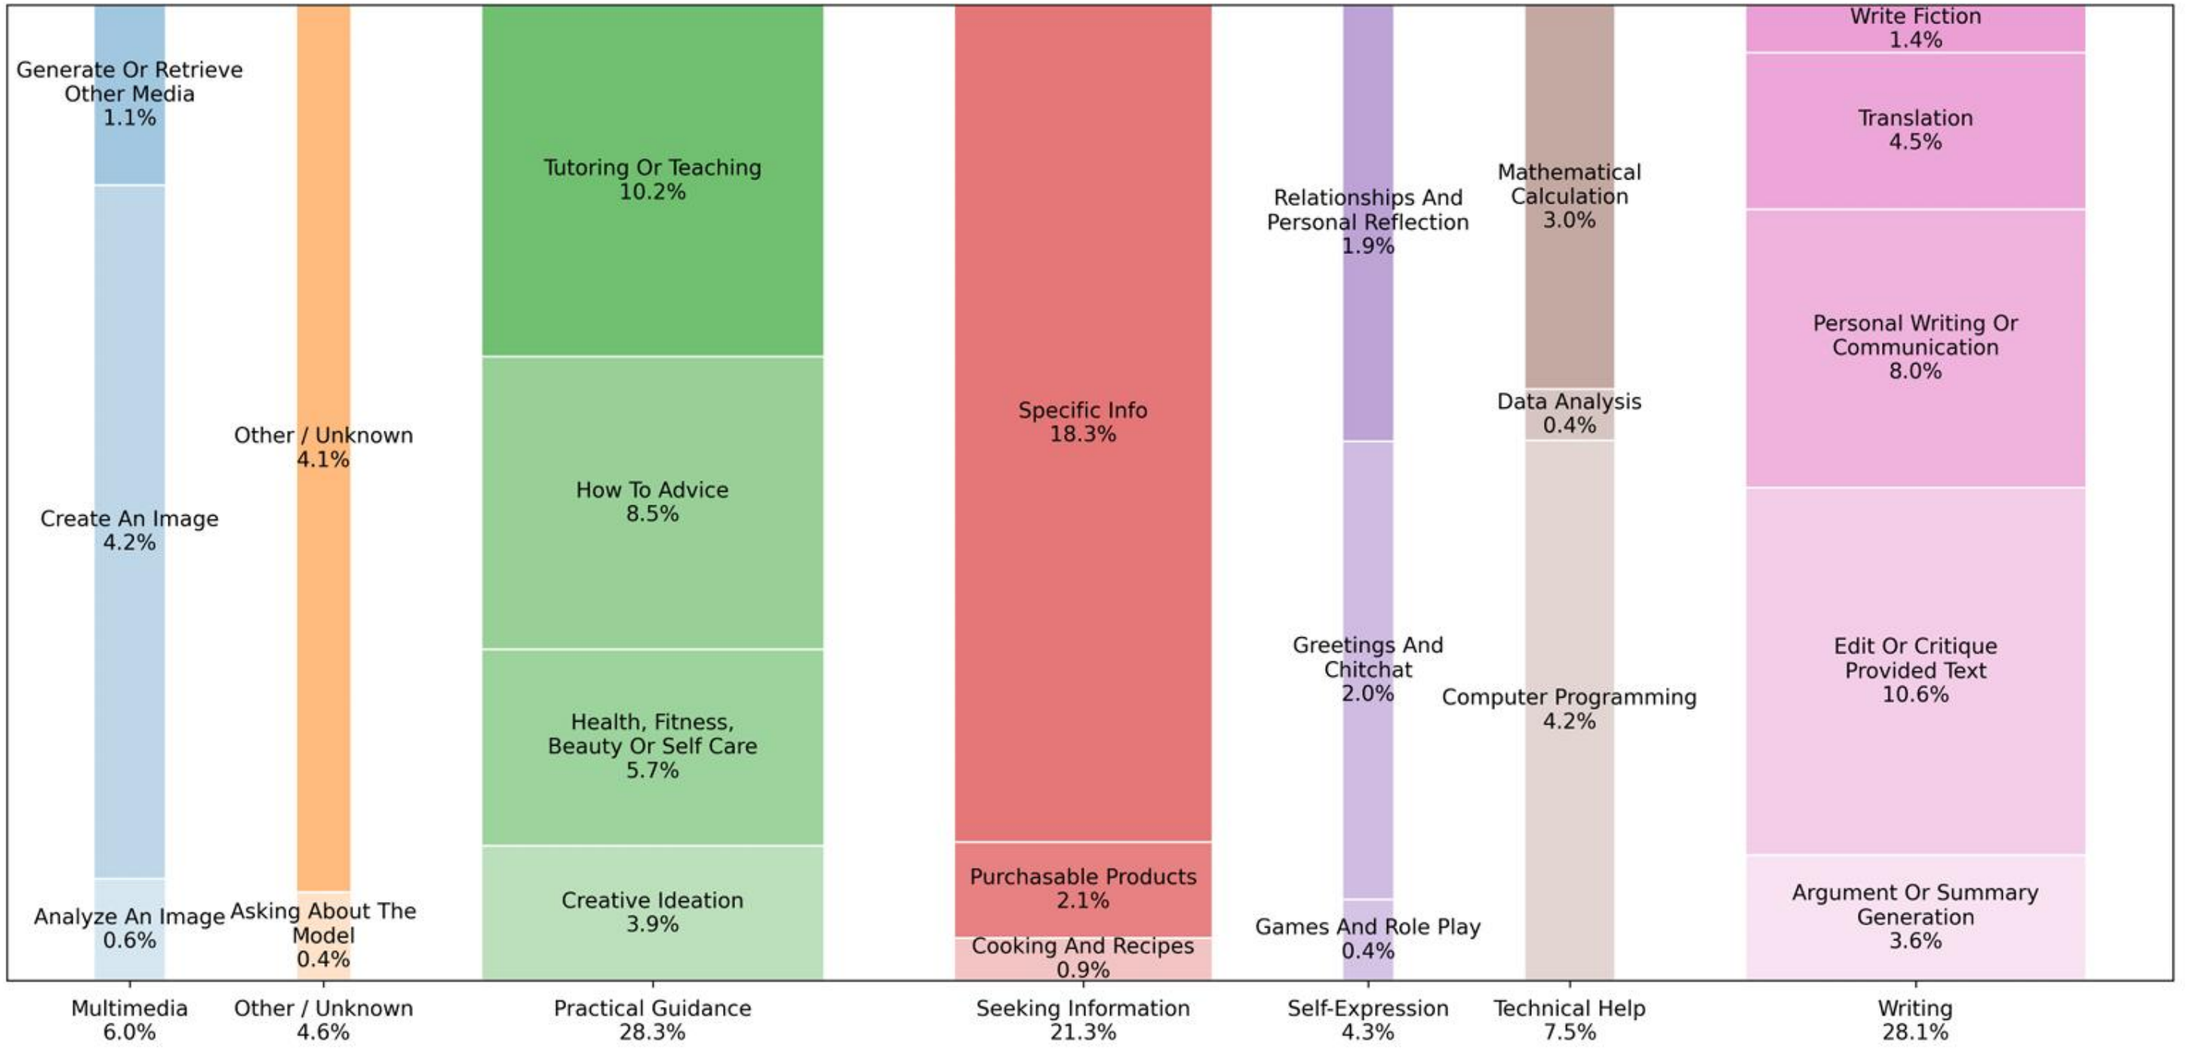
Barriers to widespread adoption #2: Customization (long tail) problem



All potential AI projects, sorted in decreasing order of value

출처 : How Data-Centric AI Bolsters Deep Learning for the Small-Data Masses (datanami.com)

다양한 AI 활용 영역



출처 : (https://cdn.openai.com/pdf/a253471f-8260-40c6-a2cc-aa93fe9f142e/economic-research-chatgpt-usage-paper.pdf

AI 활용 : 메일 작성

지난 주 회의를 깜박 잊고 불참했는데,
회의 소집한 분에게 진심을 느낄 수 있는 정중한 사과의 메일을 작성해 줘

지난 주에 참석할 회의를 깜박 잊고 불참했는데,
회의를 소집한 분에게 진심을 느낄 수 있는 정중한 사과의 메일을 작성해줘.

KSW GPT4

제목: 회의 불참에 대한 진심어린 사과

존경하는 [회의 소집자 성함]님께,

저는 지난 주에 열리는 예정이었던 회의에 참석하지 못한 점에 대해 깊은 유감을 표합니다. 이메일을 통해 진심으로 사과의 말씀을 전하고자 합니다.

먼저, 제가 회의 일정을 깜박 잊은 것은 저 자신의 부주의로 인한 큰 실수였습니다. [회의 일시]라는 중요한 정보를 간과하고 불참하게 되어 정말 죄송합니다. 제가 이러한 실수를 범한 것으로 인해 다른 참석자 분들께도 불편함을 끼쳐드렸을 가능성이 있음에 대해 깊이 반성하고 있습니다.

저는 회사 내에서 협업과 의사소통의 중요성을 알고 있으며, 이러한 사소한 실수로 인해 조직적인 업무 활동에 방해가 되지 않도록 최선을 다할 것입니다. 앞으로는 일정 관리를 철저히 하여 이와 같은 상황이 발생하지 않도록 하겠습니다.

다시 한 번, 저의 부주의로 인하여 발생한 불편함과 혼란에 대해서 진심으로 사과드립니다. [회의 소집자 성함]님께서 소중히 여기시는 회사 문화와 원활한 협업 정신을 지속적으로 배우고 발전시켜 나갈 것임을 약속드립니다.

감사합니다.

[귀하 성함

AI 활용 : 번역

언어 감지 영어 한국어 독일어

"Generative AI is a can of worms that has to be opened". That was the laconic comment from a senior industry influencer, when I shared

원문의 의미를 살리면서 자연스럽고 이해하기 쉽게 번역하면 다음과 같습니다.

> **"생성형 AI는 결국 열어**

이는 내가 MariaDB Fou
으로 단계적으로 발전시
게 남긴 말이다.

이 한마디에는 생성형 A
를 차근차근 다듬어 나

표현 해설

- **a can of worms**
  - 직역하면 "벌레통"이지만, 영어 관용어로는
    - "골치 아픈 문제"
    - "복잡하고 해결하기 어려운 사안"
    - "한 번 열면 여러 문제가 쏟아져 나오는 상황"
- 을 의미합
- 여기서는
  스가 강합

한국어 영어 일본어

"제너레이티브 AI는 열어야 하는 벌레 캔이다." 이는 제가 MariaDB 서버를 AI 솔루션용 플랫폼으로 연속적으로 만들려는 MariaDB 재단의 계획을 공유했을 때 업계 고위 영향력자의 간결한 의견이었습니다. 이 성명서 잡성과 단계적 개선의 필요성을 결합합니다.

n jega MariaDB seobeoleul AI
llyeoneun MariaDB jaedan-ui
yeogjaui gangyeolhan

따라서 의역하면 다음과 같이도 번역할 수 있습니다.

> **"생성형 AI는 복잡한 문제들을 안고 있지만, 결국은 마주하고 활용해야 할 기술이다."**

이는 내가 MariaDB Foundation의 AI 플랫폼 전략을 설명했을 때 한 업계 관계자가 남긴 짧은 평가였다. 이 말은 생성형 AI가 가진 거대한 가능성과 동시에 해결해야 할 과제들, 그리고 이를 한 번에 해결하려 하기보다 단계적으로 발전시켜 나가야 한다는 점을 함축하고 있다.

AI 활용 : 특정 정보 탐색

공시최고 판결전 대표상속인으로 등록했으면 ..
대표 상속인 관련 서류만으로 마무리 할 수 있는가/

네, 결론부터 말씀드리면 법원의 판결(제권판결)이 나온 후에는 처음에 등록하신 '대표상속인' 관련 서류와 판결문 위주로 절차를 마무리할 수 있습니다.

이미 법원에 공시최고를 신청할 때 다른 상
문에, 판결 이후 증권대행기관(한국예탁결
대폭 간소화됩니다.

다만, 금융기관 및 대행기관의 특성상 안전
다음 내용을 확인해 주세요.

1. 마무리 단계에서 필요한 핵심 서류

대표상속인 혼자 대행기관(예탁결제원, 하
서류는 다음과 같습니다.

- **법원 제권판결문 정본 (가장 중요)**
- **대표상속인의 신분증 및 인감증명서,**
- **부모님(망자) 기준의 기본증명서, 가**
- 주식을 넘겨받을 **대표상속인 명의의**

2. 기관에 따라 추가로 요구

공시최고 신청 당시에 상속인 전
제출하여 재판을 진행했더라도,
에서 서류의 '유효기간'을 문제 삼을 수 있습니다.

보통 금융기관은 인감증명서나 가족관계증명서 등의 서류 유효기간을 '발행일로부터 3개월 이내'로 제한합니다. 공시최고 재판은 최소 3~5개월 이상 걸리기 때문에, 처음에 법원에 냈던 서류들은 이미 3개월이 지나서 금융기관 기준에는 만료되었을 확률이 높습니다.

따라서 안전한 마무리를 위해 방문 전 대행기관에 전화를 걸어 아래 내용을 먼저 확인하시는 것이 좋습니다.

💡 **대행기관 방문 전 확인 체크리스트**
"공시최고 판결문이 나와서 대표상속인 명의로 주식을 이관하려고 합니다. 신청 때 다른 상속인들의 동의서를 다 제출했었는데, **실제 주식 이관 시점에 다른 상속인들의 '최근 3개월 이내 발행된 인감증명서'나 '동의서'를 다시 새로 떼어 와야 하나요?** 아니면 대표상속인 서류와 판결문만 있으면 되나요?"

요약하자면

재판을 대표상속인 이름으로 승소했기 때문에 권리는 대표상속인에게 넘어온 것이 맞고, 대표상속인 서류 위주로 마무리가 가능합니다. 다만 **다른 상속인들의 인감증명서 등을 최신본으로 다시 한 번 받아오라고 요구하는 기관이 있을 수 있으므로**, 헛걸음을 방지하기 위해 방문 전 해당 금융기관(증권대행부)에 필수 서류 유효기간을 꼭 유선으로 확인해 보시기 바랍니다.

활용 범위를 넓혀가는 AI : 신약 개발

AI로 노벨상 받은 베이커 교수, 코브라 독 해독제 개발

2025.01.16 01:00

인공지능(AI)을 활용한 단백질 설계 연구로 2024년 노벨화학상을 받은 데이비드 베이커 워싱턴대 교수팀이 치명적인 독사인 코브라의 독을 중화하는 해독제를 개발했다.

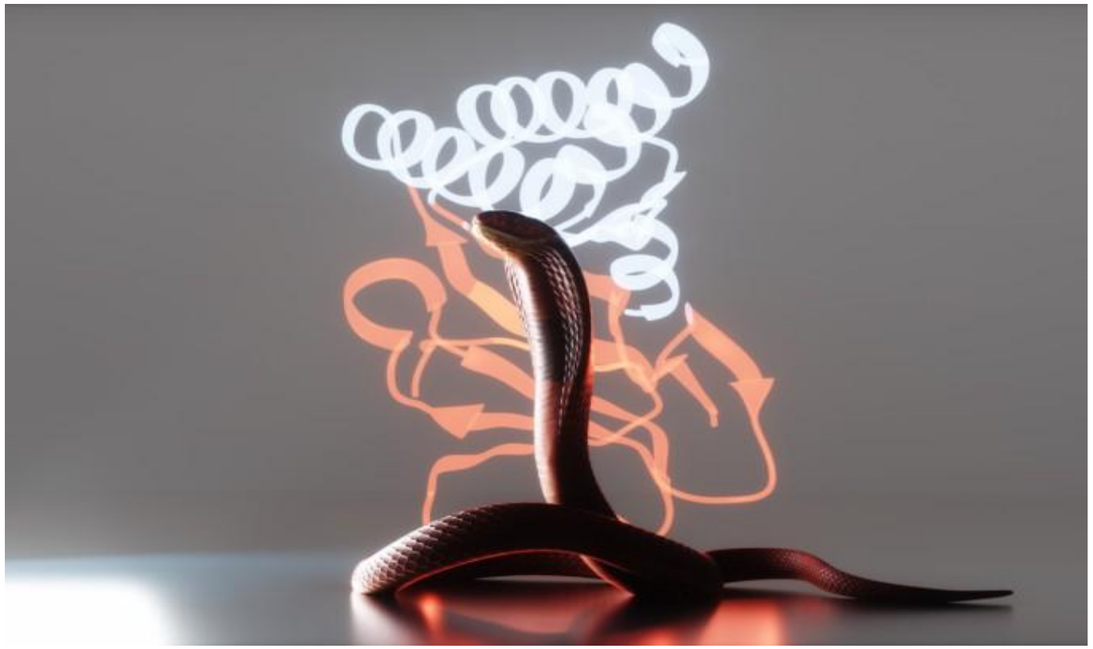
베이커 교수팀은 덴마크 공과대 연구팀과 함께 코브라 독을 중화시키는 단백질을 AI로 설계해 만들고 연구결과를 15일(현지시간) 국제학술지 '네이처'에 공개했다. AI로 만든 해독제는 기존 해독제보다 안전하고 생산 비용이 저렴해 독사 피해가 많은 아프리카, 아시아 등 취약 지역에 도움이 될 것으로 기대된다.

2023년 세계보건기구(WHO) 발표에 따르면 해마다 180~270만명의 사람들이 독사에 물려 약 10만명이 사망한다. 사망자보다 약 3배 많은 사람들은 영구적인 장애를 입는다. 독사의 독은 주로 신경계와 세포에 작용해 마비와 호흡장애, 출혈장애 등을 일으켜 사지 절단 등 영구적인 신체 손상을 유발한다.

현재 독사의 독을 해독하는 유일한 치료법은 해당 독에 면역이 있는 동물의 혈장에서 추출한 항체를 이용하는 방법이다. 혈장 추출 항체 해독제는 제조 비용이 많이 들고 코브라 등 일부 독사의 독에는 효능이 제한적이다. 부작용이 나타나는 경우도 많다. 독소는 뱀의 종류에 따라 다양하기 때문에 각 지역에 맞는 해독제와 치료법 연구가 필요하다.

연구팀은 코브라의 독처럼 인간 면역 체계를 우회해 혈장 추출 방식 해독제가 잘 듣지 않는 '세손가락독소(3FTx, Three-finger toxins)' 계열 독소와 결합해 중화하는 단백질을 설계했다. 이 단백질은 열 안정성, 독소와의 높은 결합력 등을 보였다.

쥐 실험으로 연구팀이 개발한 단백질의 해독 성능도 테스트했다. 그 결과 치사량의 3FTx 계열 독소 3종류로부터 쥐의 생존율은 80~100%까지 확보됐다.



크기가 작은 AI 설계 단백질은 조직에 더 잘 침투해 기존 해독제보다 독소 중화 효과가 더 컸다. 또 개발 시간이 짧고 미생물을 사용해 제조할 수 있어 생산 비용도 저렴하다. 베이커 교수는 "설계 소프트웨어가 워낙 좋아져서 몇 가지 분자만 테스트하면 됐다"고 설명했다.

이번에 개발된 단백질은 새로운 치료법으로 승인될 때까지 기존 치료법 효과를 개선하는 보조제나 강화제로 쓰일 것으로 전망된다.

연구팀은 "AI 단백질 설계는 유해 단백질을 중화시키는 데 활용될 수 있다"며 "독사 물림 치료 외에 잘 연구되지 않은 열대성 질병에 대한 치료제 개발 비용도 줄일 수 있을 것"이라고 말했다.

출처 : https://www.dongascience.com/news.php?idx=69549

활용 범위를 넓혀가는 AI : AI 변론 작성

2026.05.22 11:43

AI로 소송 이긴 일반인…전문직 흔든다

국내서 AI 활용 '나홀로 소송' 승소 사례 등장
미국선 변호사 없이 AI로 소송 준비하는 사례 확산
법률 접근성 커졌지만 책임·검증 공백은 과제

[MS투데이] 인공지능(AI)을 활용해 일반인이 변호사를 상대로 한 소송에서 승소한 국내 사례가 알려지면서 법률서비스 시장의 변화 가능성이 주목받고 있다. 단순한 문서 작성 보조를 넘어 소장 분석, 법리 검토, 반박 서면 작성 등 기존에는 변호사 조력이 필요했던 영역에 AI가 빠르게 파고들고 있어서다. 법률 비용 부담을 낮추고 일반인의 사법 접근성을 높일 수 있다는 기대와 함께, 잘못된 법률 정보와 책임 소재를 둘러싼 우려도 커지고 있다.

최근 국내 보도에 따르면 한 일반인은 과거 선임했던 변호사와 분쟁을 겪은 뒤 법무법인을 상대로 한 민사소송과 형사 고소 대응 과정에서 AI를 활용했다. 그는 변호사 선임이 여의치 않은 상황에서 AI에 사건 경위와 서류 내용을 입력하고, 고소장 분석과 법리 검토, 반박 의견서 작성을 도움받은 것으로 전해졌다. 결과적으로 형사 사건은 혐의없음 판단을 받았고, 민사소송에서도 최종 승소했다. 법률 전문가를 직접 대리인으로 선임하지 않고도 AI를 보조 도구로 활용해 분쟁에 대응한 사례라는 점에서 관심을 끌었다.

◆ 국내 사례가 던진 질문…AI는 어디까지 도울 수 있나

이번 사례는 AI가 변호사를 대체했다기보다, 비전문가가 법률 절차를 이해하고 서면을 정리하는 데 AI를 활용했다는 데 의미가 있다. 실제 소송에서는 사실관계 정리, 증거 제출, 절차 준수, 법리 구성 등이 모두 필요하다. 일반인에게는 진입장벽이 높은 영역이지만, 생성형 AI는 복잡한 법률 용어를 쉽게 풀어 설명하고 주장 구조를 정리하는 데 도움을 줄 수 있다.

다만 AI가 제시한 답변이 항상 정확한 것은 아니다. 존재하지 않는 판례를 제시하거나 법령 해석을 잘못할 가능성이 있다. 법률 문서의 최종 책임도 AI가 아니라 이를 제출한 당사자에게 있다. 이 때문에 법조계에서는 AI가 소액 사건이나 단순 분쟁에서 보조 수단이 될 수는 있지만, 사실관계 다툼이 크거나 법률 쟁점이 복잡한 사건에서는 전문가 검토가 여전히 필요하다는 신중론이 나온다.

◆ 미국선 AI 자력소송 확산…법원 부담도 커져

해외에서도 비슷한 흐름이 나타나고 있다. 외신에 따르면 미국에서는 변호사 비용을 감당하기 어려운 시민들이 AI를 활용해 민사소송 서류를 작성하고 법적 절차를 준비하는 사례가 늘고 있다. 한 미국 시민은 임대인과의 분쟁에서 변호사를 찾지 못하자 AI 도구를 활용해 연방법원에 소송을 제기했다. AI는 청구 취지 정리, 절차 안내, 상대방 주장 분석 등에 활용됐다.

자력소송 증가세도 확인된다. 외신은 2025 회계연도 미국 연방법원 민사사건에서 변호사 없이 스스로 소송을 진행한 당사자의 비중이 약 17%로 장기 평균보다 높아졌다고 전했다. AI가 법률서비스 접근성을 넓히는 도구가 될 수 있다는 분석이 나오는 배경이다. 하지만 법원 입장에서는 AI가 만든 부정확한 서면, 과도한 제출 문서, 허위 판례 인용 등이 새로운 부담으로 떠오르고 있다.

◆ 전문직 역할, 작성자에서 검토자로 이동

AI 법률 활용을 둘러싼 책임 논쟁도 본격화하고 있다. 최근 미국에서는 ChatGPT가 무자격 법률행위를 했다는 취지의 소송이 제기됐고, AI 개발사는 "ChatGPT는 변호사가 아니며 법률행위를 하지 않는다"는 입장을 법원에 냈다. 이용자가 AI 답변을 법률 조언처럼 활용할 수는 있지만, 그 결과에 대한 책임은 도구가 아니라 사용자에게 있다는 논리다.

이 논쟁은 법률시장을 넘어 회계, 세무, 노무, 의료 자문 등 전문직 전반으로 확산될 수 있다. AI가 초안 작성과 자료 검색, 쟁점 정리 같은 반복 업무를 빠르게 처리하면서 전문직의 역할은 단순 문서 작성자에서 최종 검토자, 전략 판단자, 책임 주체로 이동하고 있다. 소비자 입장에서는 비용 절감과 접근성 확대라는 장점이 있지만, 검증되지 않은 AI 답변을 그대로 사용할 경우 손실도 본인이 떠안을 수 있다.

전문직 시장의 변화는 이미 시작됐다. AI가 법률서비스의 문턱을 낮추는 도구가 될지, 부정확한 정보와 책임 공백을 키우는 위험 요인이 될지는 제도와 시장의 대응에 달려 있다. 분명한 것은 AI가 더 이상 보조 검색 도구에 머물지 않고, 전문직의 업무 방식과 수익 구조를 바꾸는 변수로 부상했다는 점이다.

출처 : https://www.mstoday.co.kr/news/articleView.html?idxno=101625

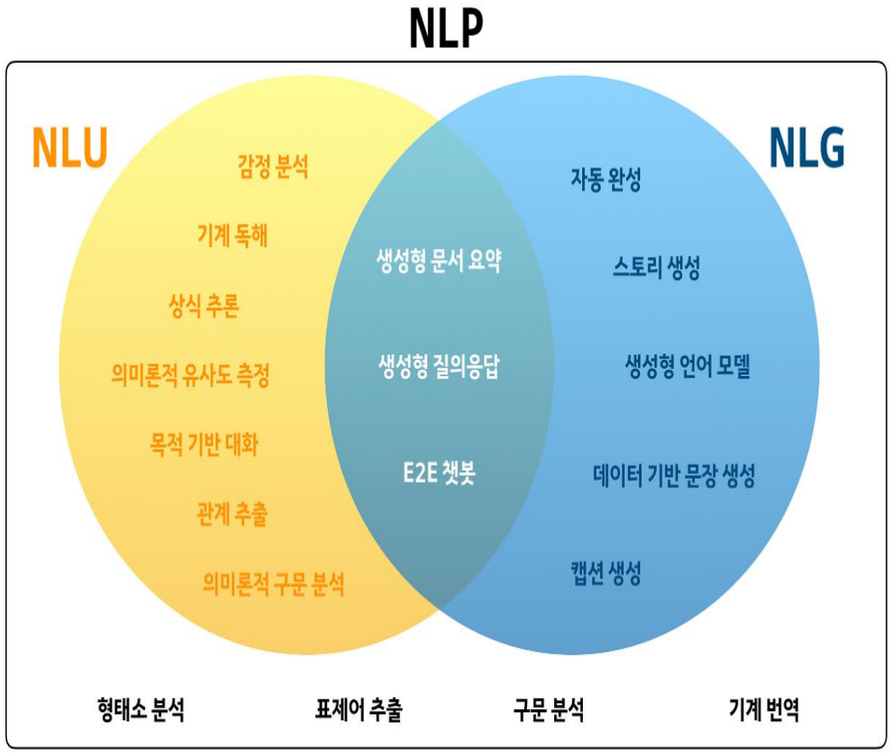
주요 기술과 특성

주요 기술과 특성

- 훈련 과정

자연어 처리 (NLP – Natural Language Processing)

- 자연어(Natural Language) : 일상 생활에서 사용하는 언어
- 자연어 처리 : 자연어의 의미를 분석하여 컴퓨터가 처리할 수 있도록 하는 일
- 대표적인 NLP 연구 분야
  - ✓ 음성 인식, 문서 요약, 번역, 감성 분석
  - ✓ 텍스트 분류 : 스팸 분류, 뉴스 카테고리 분류
  - ✓ 질의 응답, 챗봇
- NLP = NLU + NLG



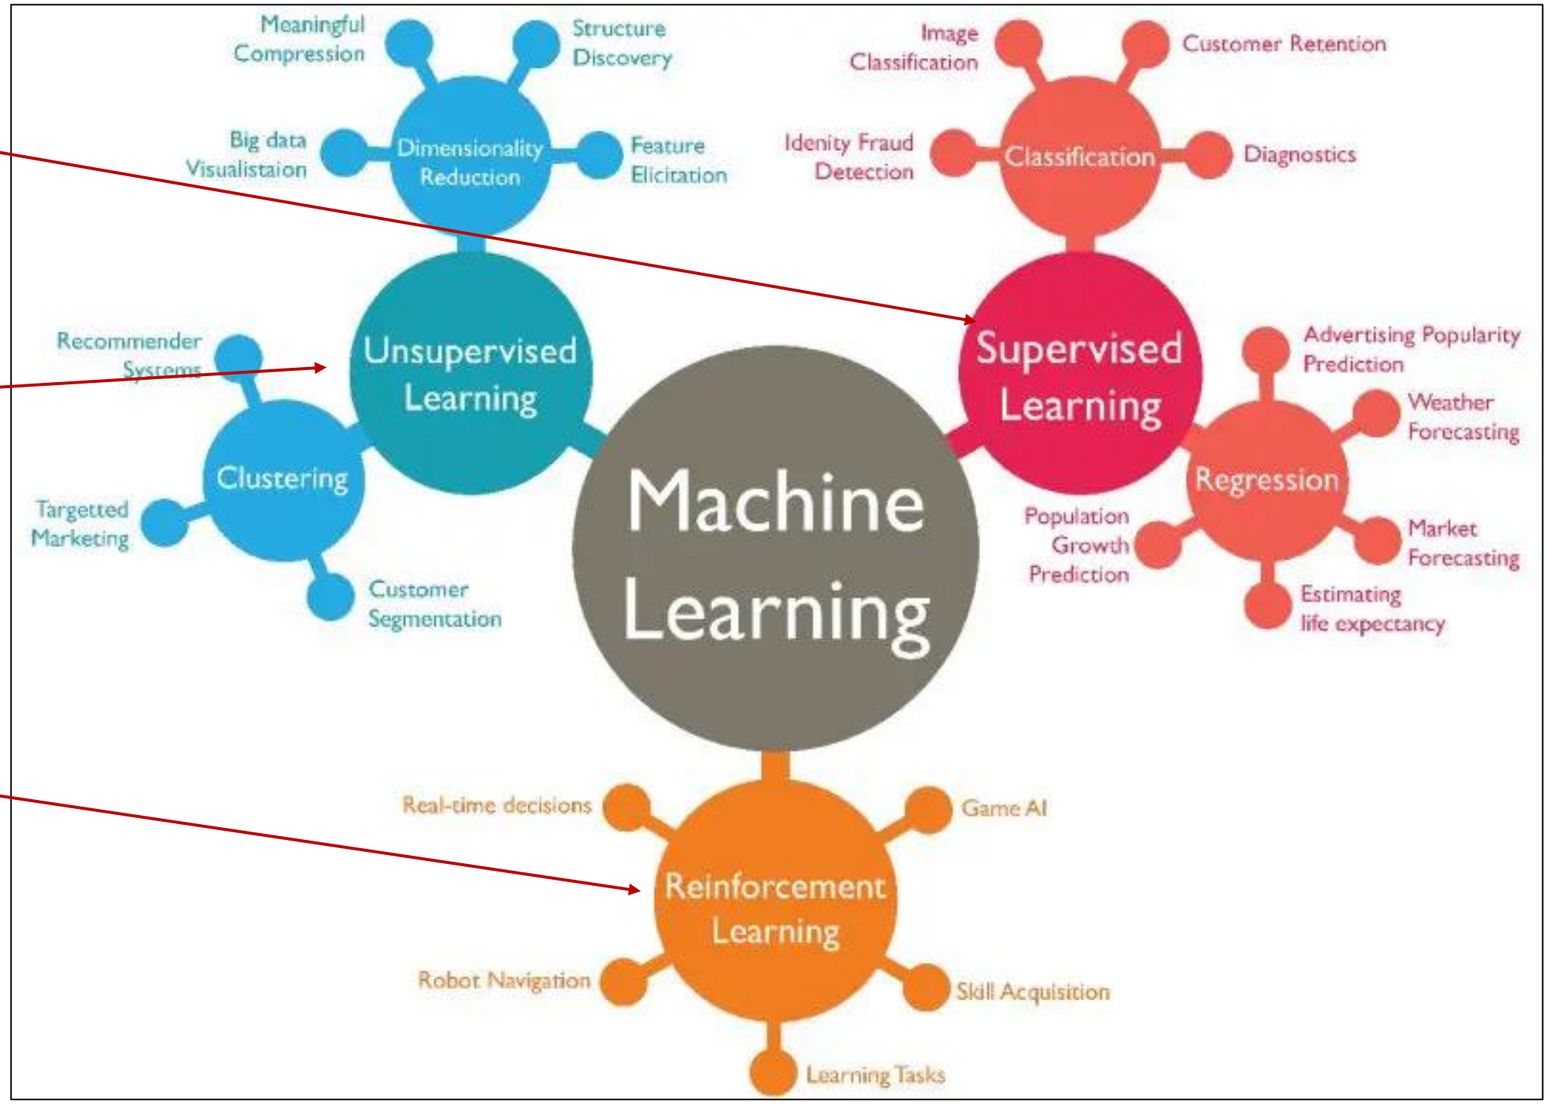
이미지 출처 : https://woongsin94.tistory.com/341

AI 학습법과 효과

지도학습 : 기존지식 전달

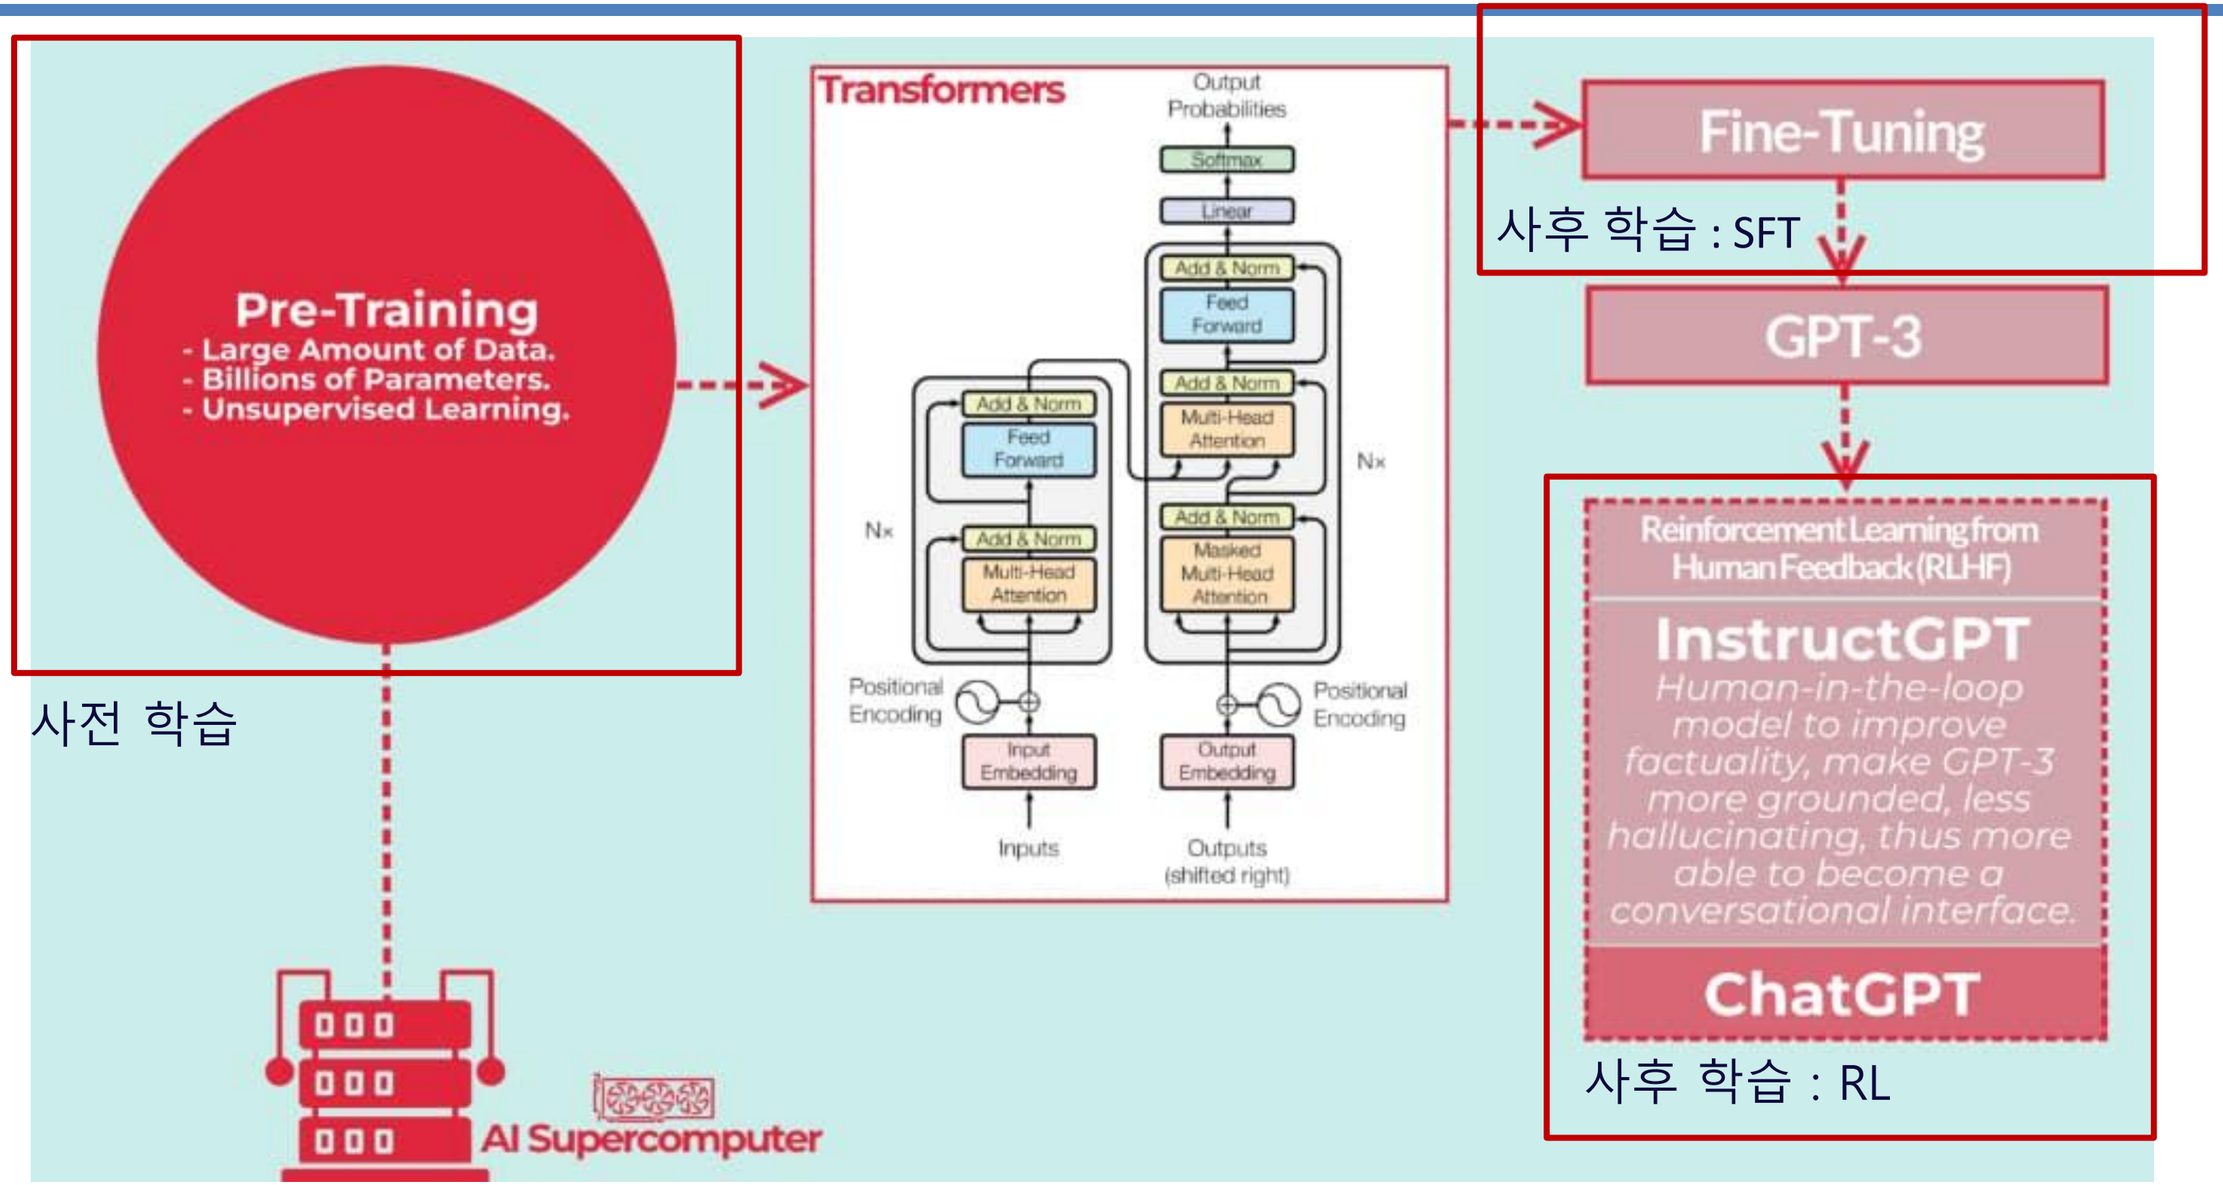
비지도학습 : 특성 패턴 찾기

강화학습 : 탐색 및 시행 착오



이미지 출처: https://datasciencedojo.com/blog/machine-learning-101/

챗GPT를 위한 훈련 (Training)



이미지 출처 https://www.theinsaneapp.com/2023/05/everything-about-instructgpt.html

선호도 훈련에 의한 논리적 약점

1.2 는 1.11 보다 작은가?

네, 1.2는 1.11보다 작습니다. 1.2
표현된 수입니다. 따라서 두 수를

아닌거 같은데

제가 이전에 제공한 답변이 잘못

아니요, 1.2는 1.19보다 큽니다.

1.2는 소수점 두 번째 자리가 0이므로 1.20으

이유는 소수점 첫째 자리에서 동일하고, 둘째
며, 이는 1.19보다 큽니다.

잘못된 설명을 드려서 죄송합니다!

SK 1.2와 1.11 중에 어느 게 커?

문자열로 비교할 때와 숫자로 비교할 때 결과가 다릅니다:

1. 문자열 비교 (사전식 순서)의 경우:
   - "1.11"이 "1.2"보다 더 작습니다.
   - 왜냐하면 문자열은 왼쪽부터 한 글자씩 비교하기 때문입니다.
2. 숫자로 비교할 경우:
   - 1.11이 1.2보다 큽니다.
   - 1.11은 1.11로, 1.2는 1.20으로 해석되기 때문입니다.

따라서 숫자로 비교한다면 1.11이 더 큽니다.

선호도 훈련의 결과

죄송합니다. 제 이전 답변을 다시 확인해보겠습니다.

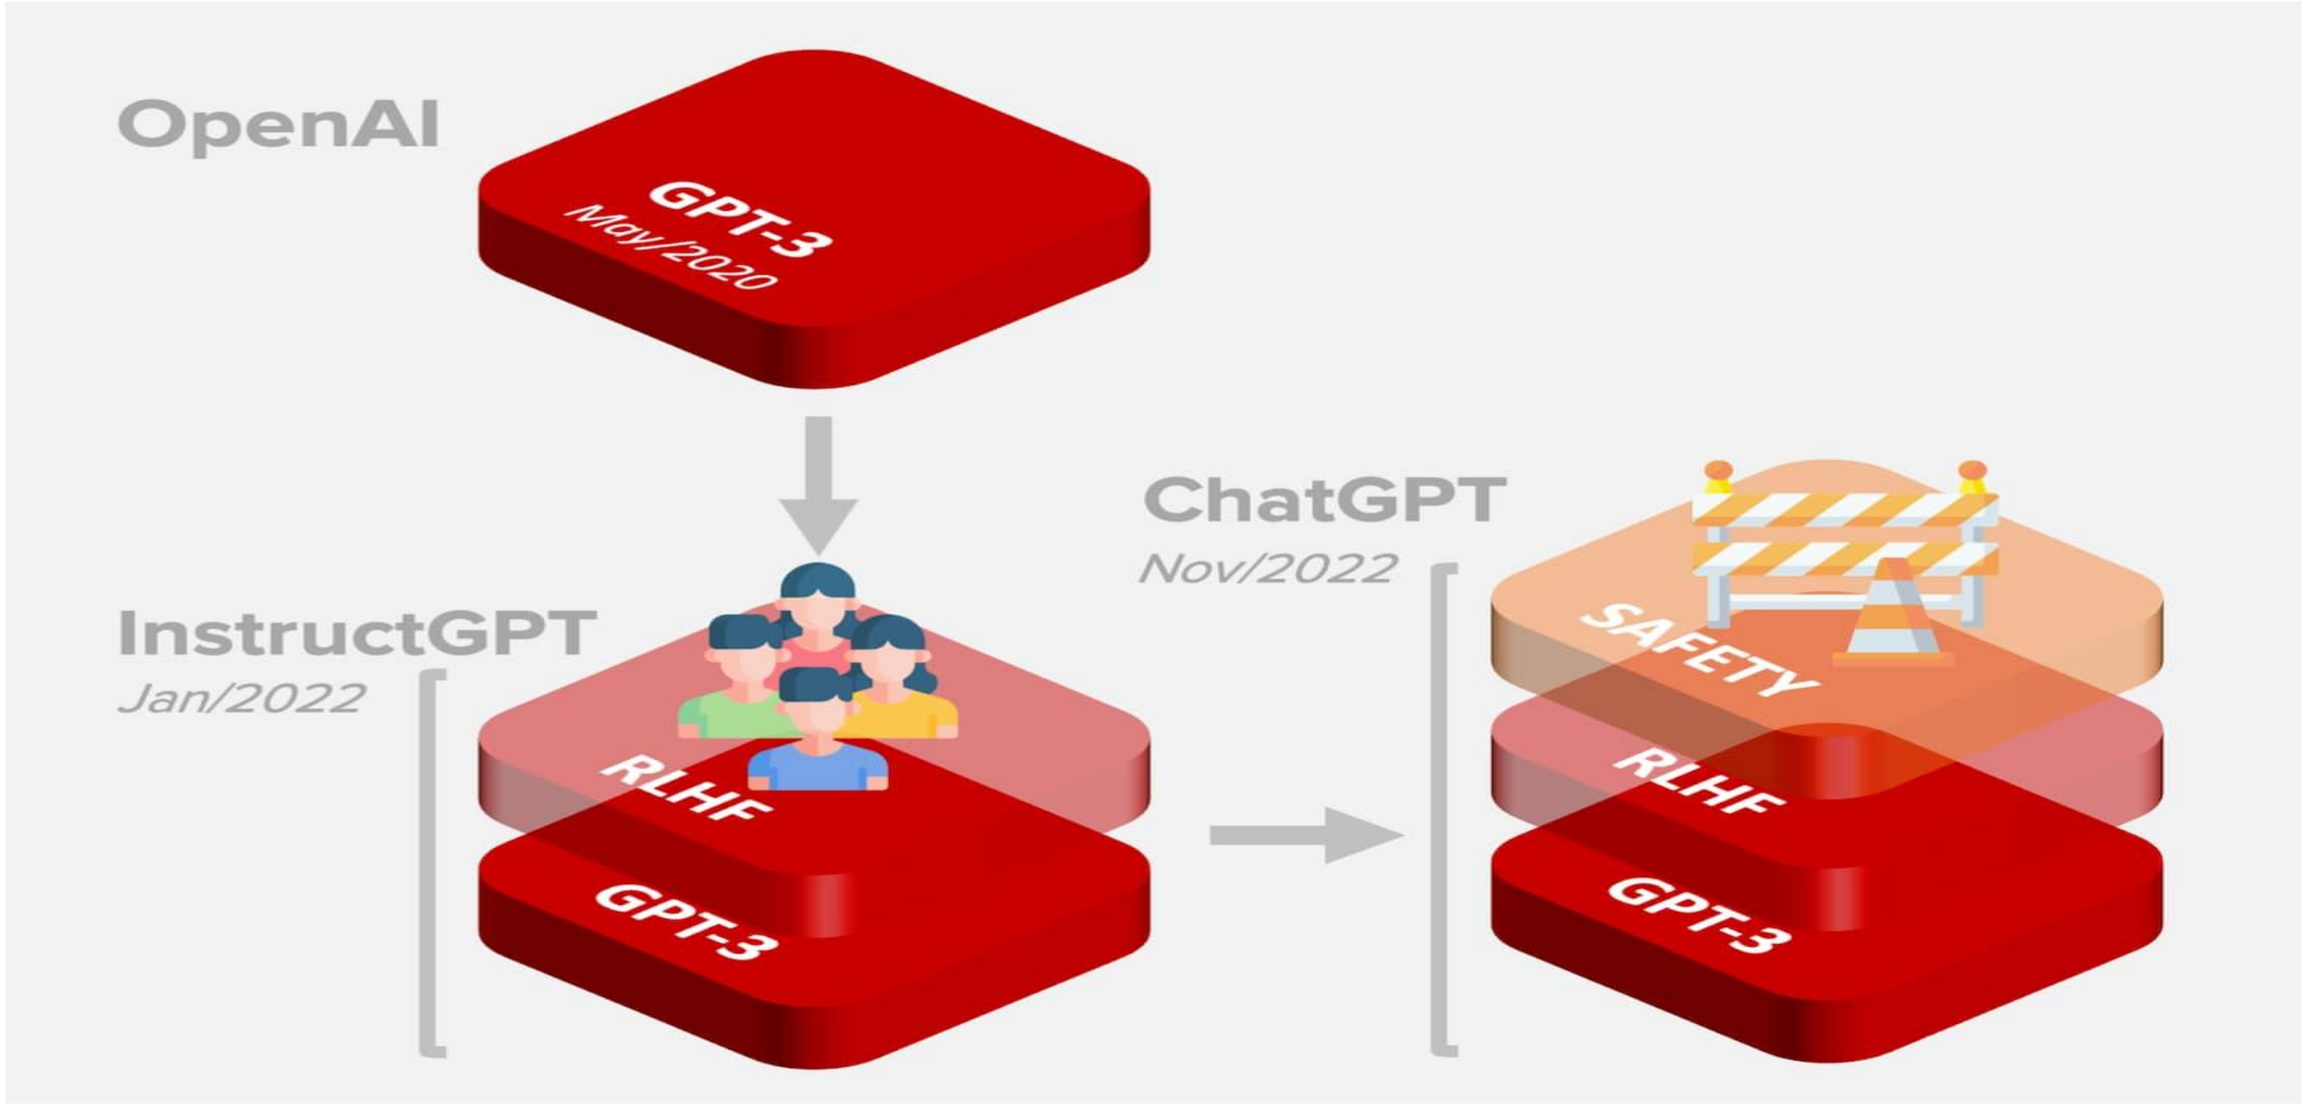
숫자로 비교했을 때, 1.2가 1.11보다 더 큽니다.

이유를 설명드리면:

- 1.2는 1.20과 같습니다.
- 1.11은 0.11보다는 크지만 1.2보다는 작습니다.

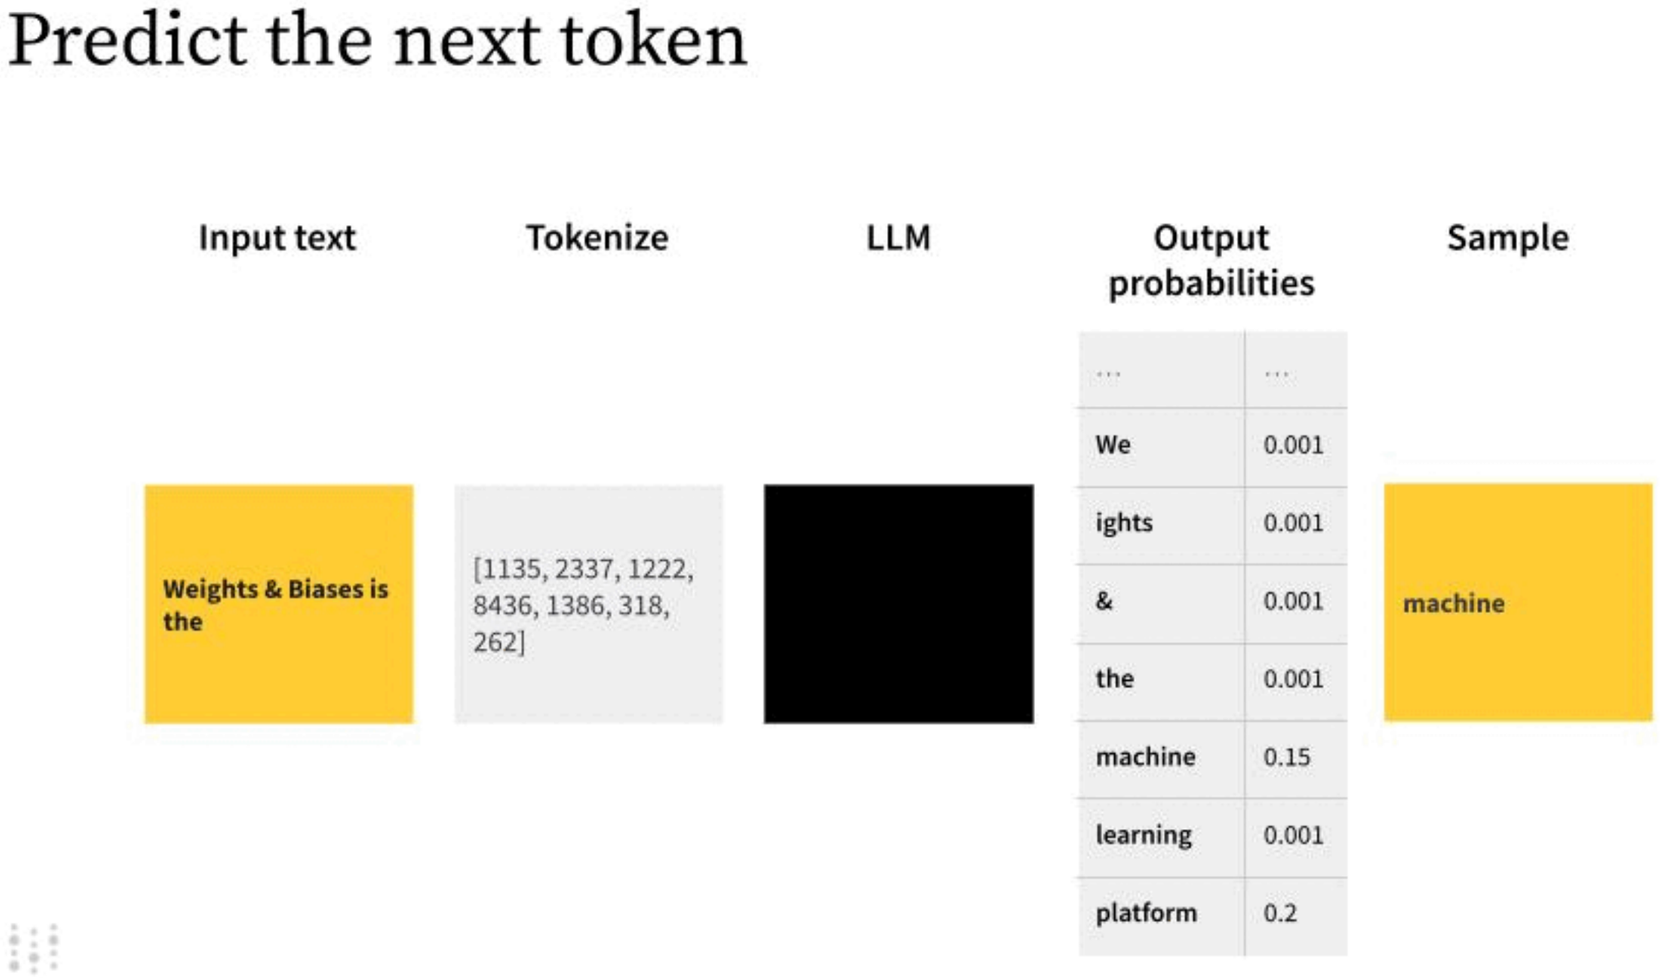
즉, 1.2가 1.11보다 더 큰 숫자입니다.

GPT, InstructGPT, ChatGPT



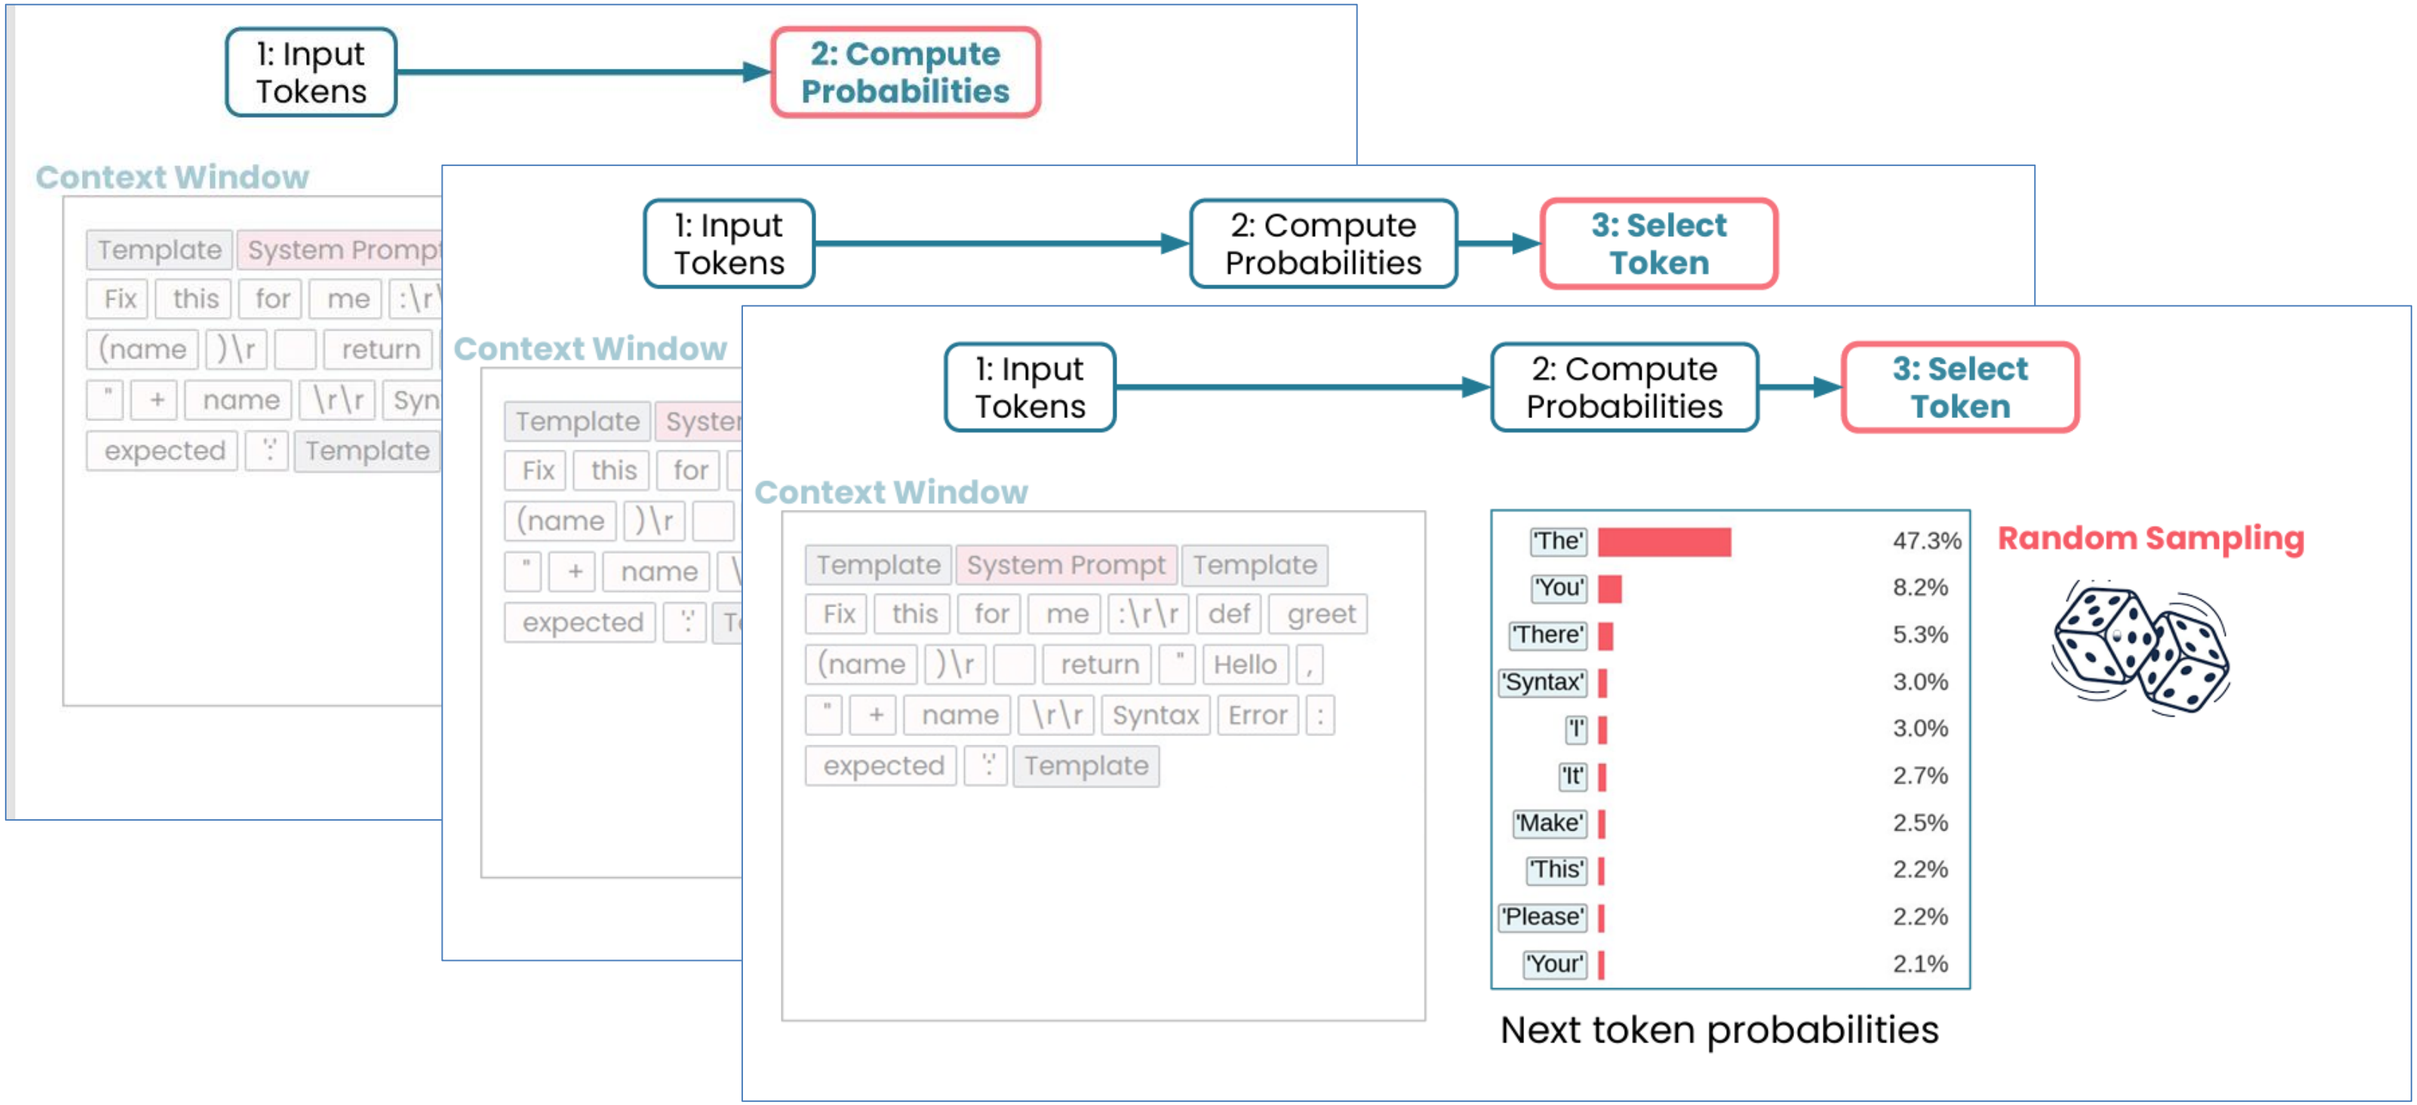
이미지 출처 https://www.theinsaneapp.com/2023/05/instructgpt-vs-chatgpt.html

AI, 확률적 다음 토큰 예측



이미지 출처 https://wandb.ai/darek/llmapps/reports/A-Gentle-Introduction-to-LLM-APIs--Vmlldzo0NjM0MTMz

언어 생성 모델 : 2가지 확률적 선택



확률적 생성 수학적 오류 : 들쑥날쑥 AI (Jagged Frontier)

76493 x 38215 =

오전 6:08

76493 × 38215 = **2,923,890,995**

76493 x 38215 =

하지만 LLM의 내부 신경망(Transformer 구조)은 이 과정을 시각적으로 보거나 순서대로 기억하지 못합니다.

- **앞자리와 뒷자리는 맞춥니다:** 앞부분인 `7 × 3 = 21`과 받아올림을 감안해 대략 `2,92...`로 시작한다는 스케일은 맞춥니다. 맨 끝자리도 `3 × 5 = 15`이므로 `5`로 끝난다는 것을 통계적 패턴으로 잘 찾아냅니다.
- **가운데 자리에서 무너집니다:** 5줄의 중간 계산값을 자릿수에 맞춰 더하는 과정에서 수많은 '받아올림(Carry)'이 발생하는데, LLM은 이를 하나씩 기억하며 더하는 **루프(반복 연산) 기능이 뇌 구조상 없습니다.** 결국 중간 자릿수(`...179...` 부분)는 계산 알고리즘이 아니라 "자신이 학습한 데이터 중에서 가장 그럴듯해 보이는 숫자의 흐름"을 확률적으로 찍어서 채우게 되며, 이 과정에서 반드시 오류가 발생하게 됩니다.

$76,493 \times 38,215 = 2,923,$

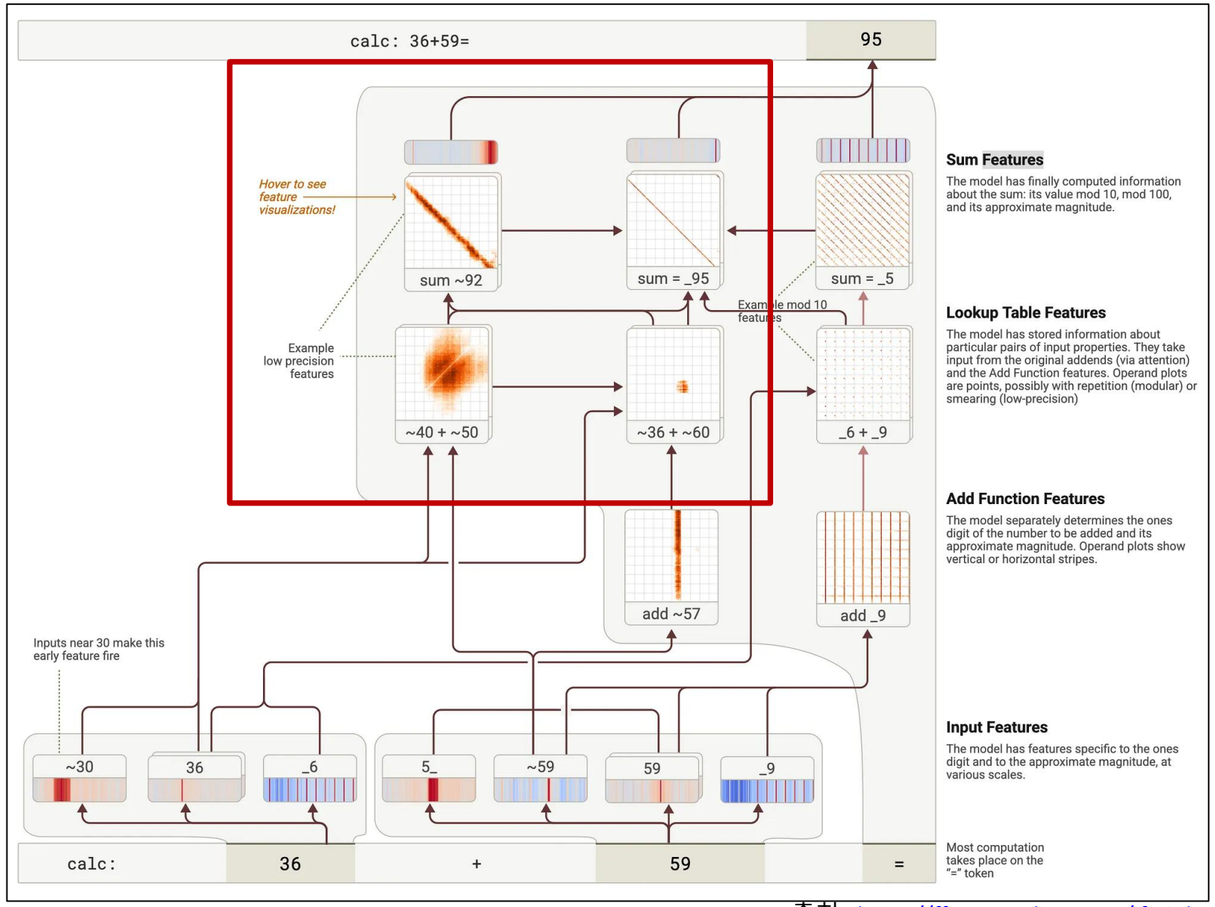
정답: **2,923,179,995**.

코드 표시 ‹›

$$76493 \times 38215 = 2923179995$$

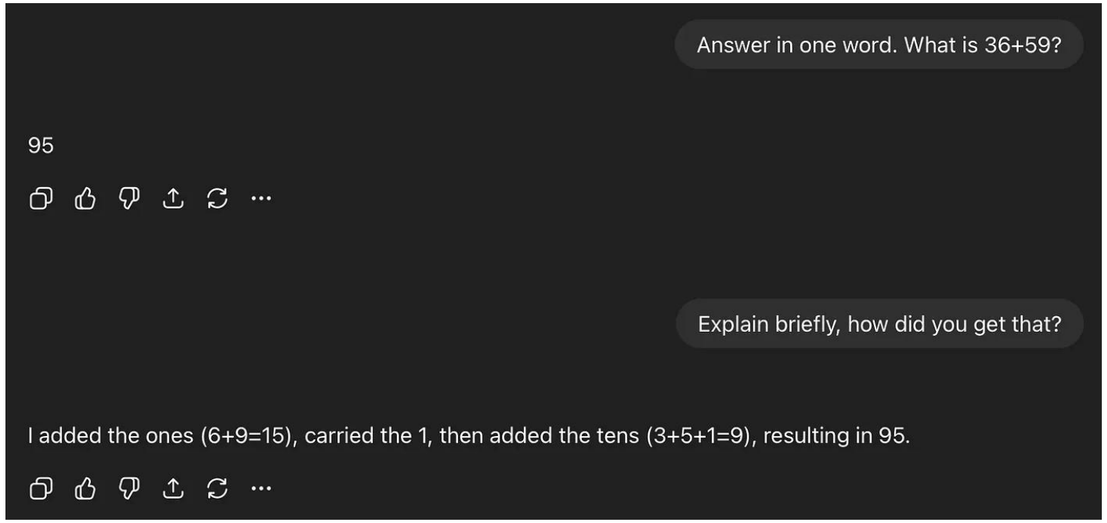
LLM 의 계산은 대충? ➔ 확률적 계산

```
36 + 59 =
```



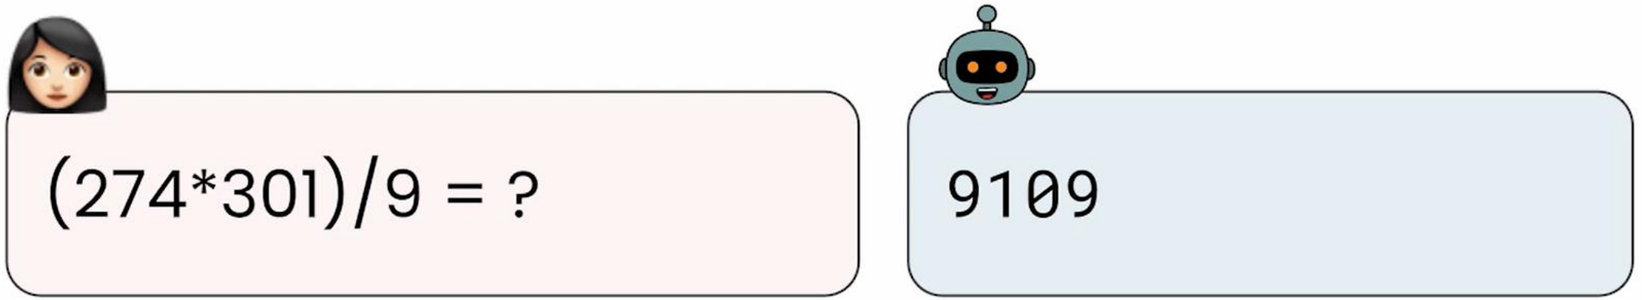
출처 : https://fferoz.medium.com/if-ai-doesnt-think-why-can-it-do-math-311493d3cffa



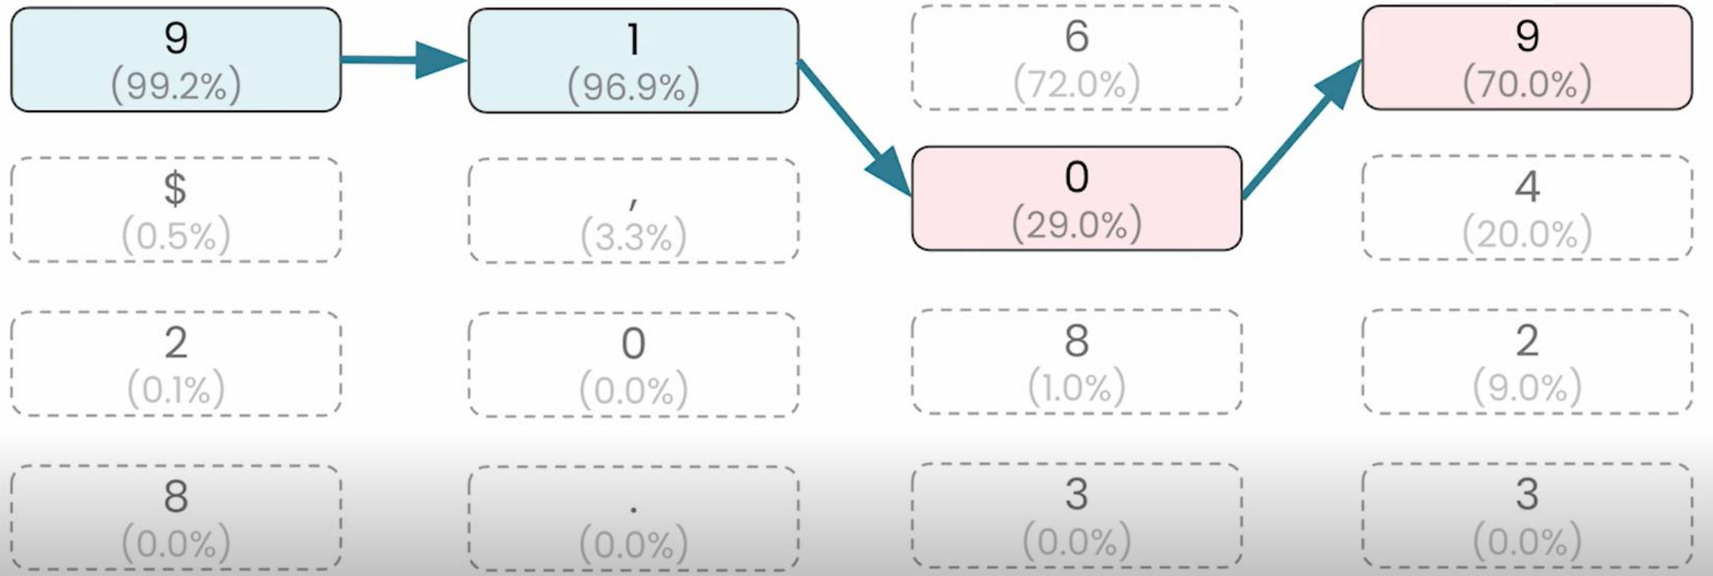


출처

LLM 의 계산은 대충? ➔ 확률적 계산



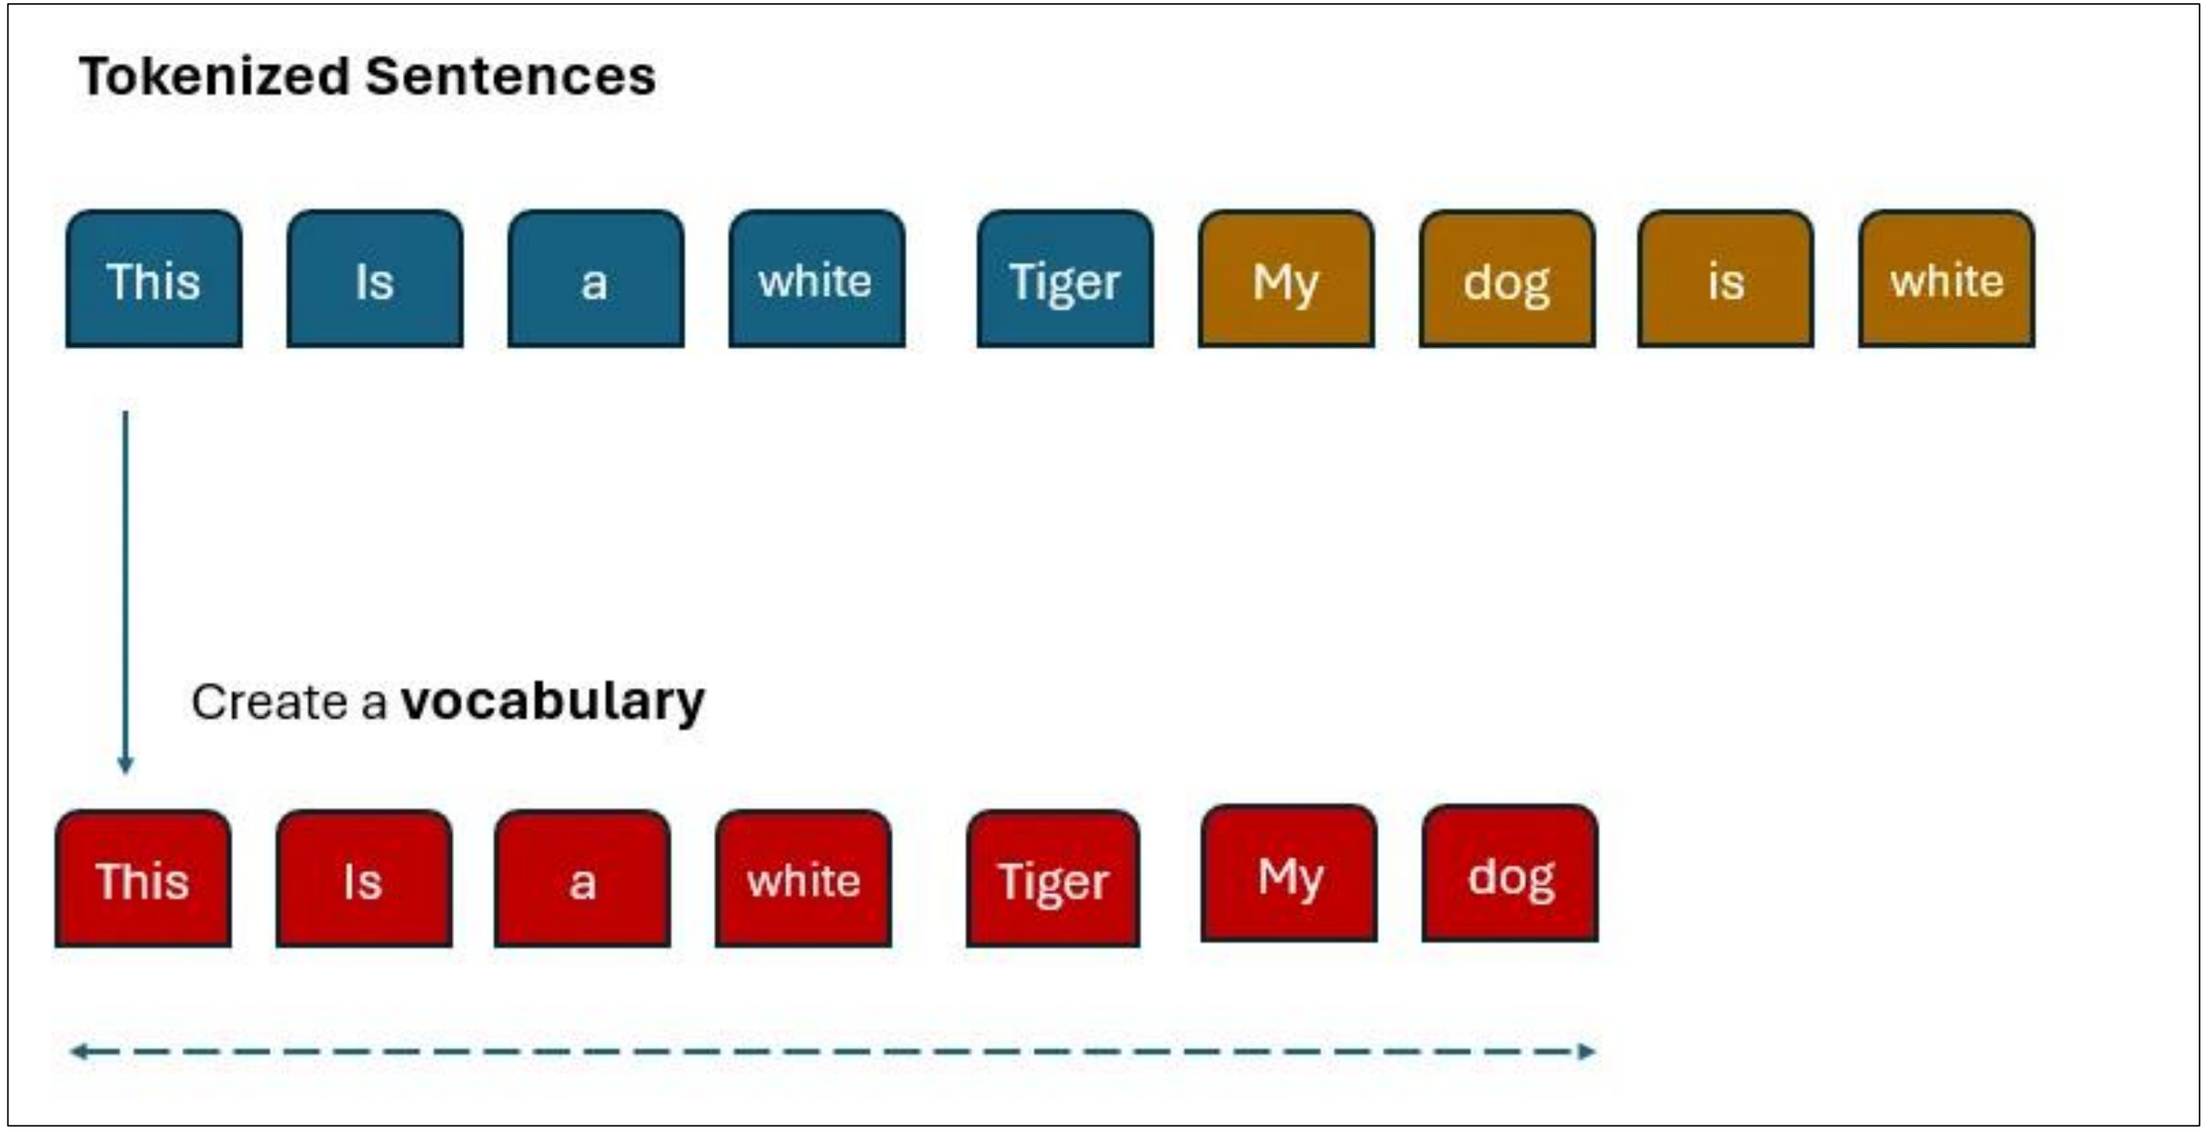
Correct answer: **9163.78**



주요 기술과 특성

- 구조적 특성

Bag of Words : Token, Vocabulary



출처 : https://vinaykuma201.medium.com/language-models-building-blocks-db81dea90174

실습 : ChatGPT 토큰 (Link : https://platform.openai.com/tokenizer)

GPT-4

Model	Prompt	Completion
8K context	$(	
32K context	$(	

GPT-3 Codex

I go to school.

Tokens 5

Character 15

I go to school.

[40, 467, 284, 1524, 13]

GPT-3.5 & GPT-4 GPT-3 (Legacy)

나는 학교에 간다.

Clear Show example

Tokens 11

Characters 10

나는 ����에 ��다.

TEXT TOKEN IDS

Chat

Model Usage

okens

GPT-4o & GPT-4o mini GPT-3.5 & GPT-4 GPT-3 (Legacy)

나는 학교에 간다.

Clear Show example

Tokens 6

Characters 10

나는 학교에 간다.

Text Token IDs

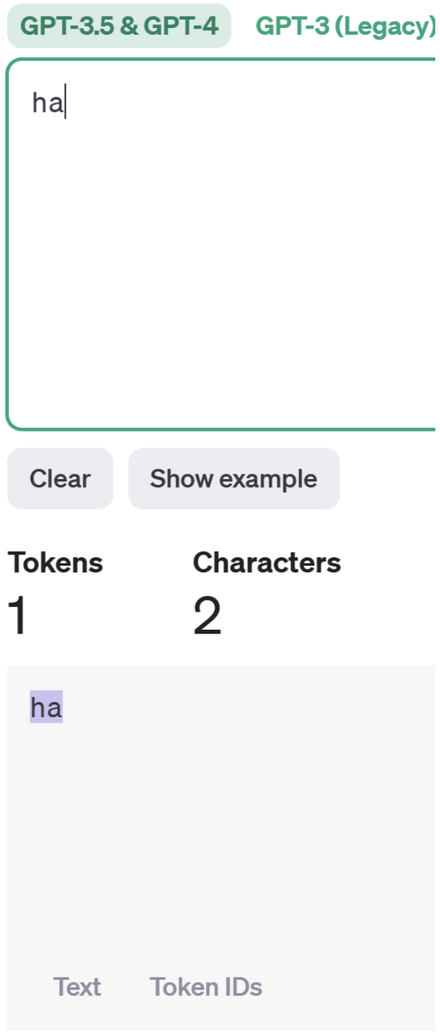
수) ~
5400 (token)

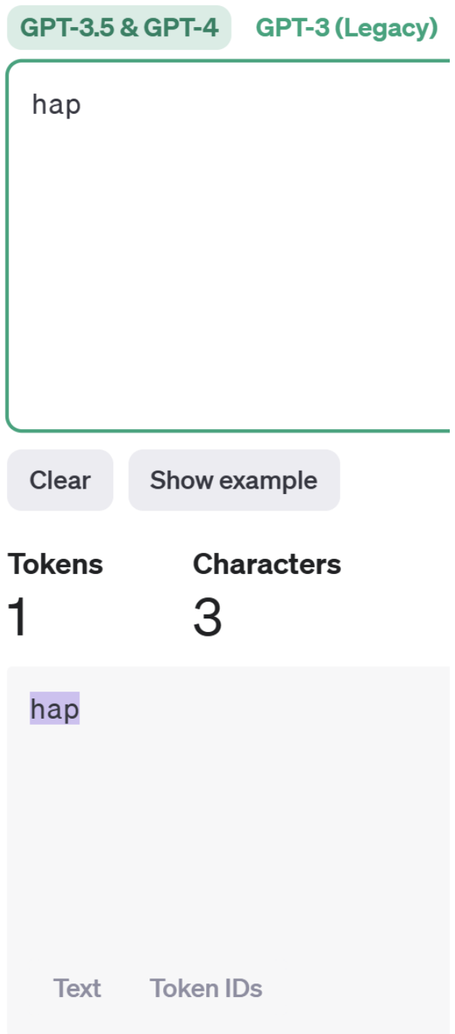
13, 238, 168, 245,
238, 220, 166, 108, 226, 46695, 97, 13]

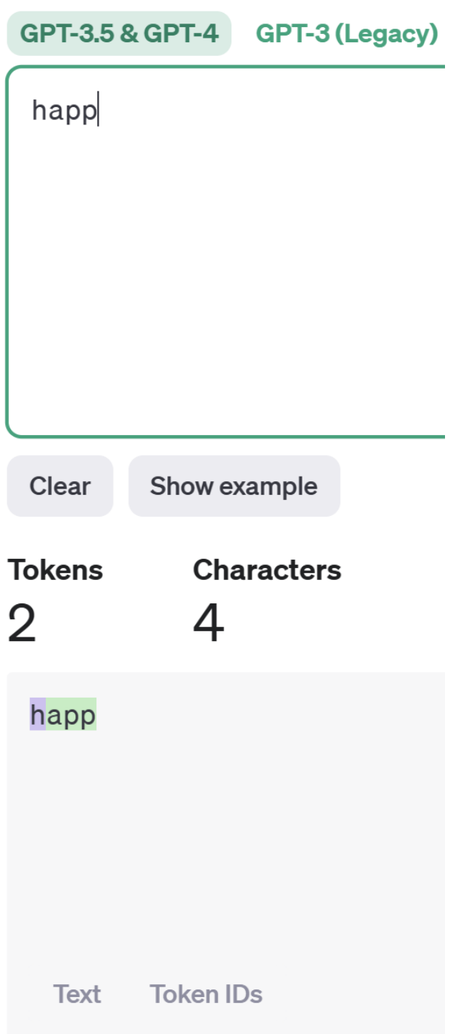
(영어 단어 수) = 0.75*(토큰 수), (한글 글자수) = 0.33 *(토큰 수)

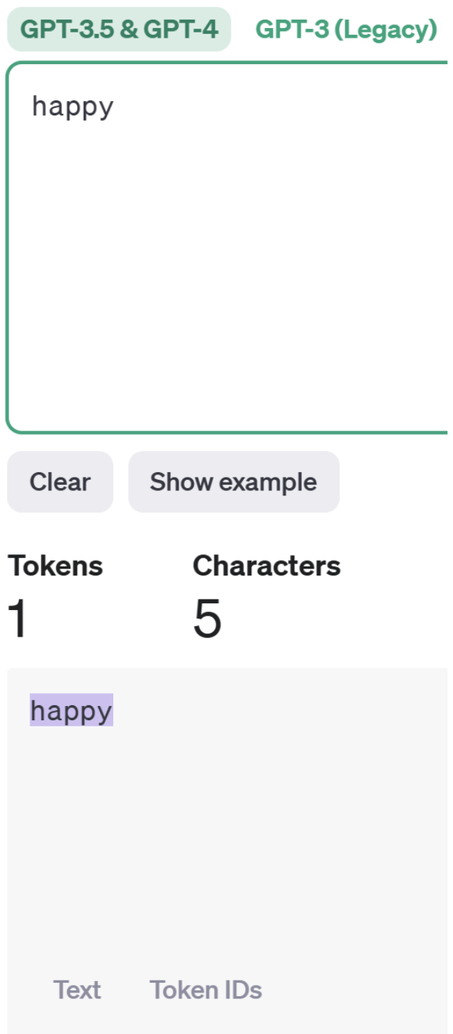
생성 컨텐츠 길이 제한, 가격 차이

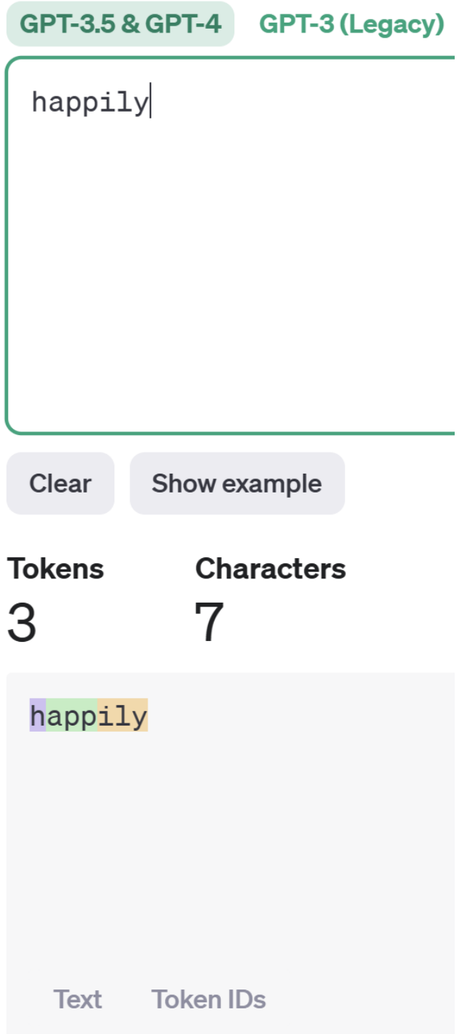
실습 : ChatGPT 토큰 (Link : https://platform.openai.com/tokenizer)











논리력 테스트 : 문자 수 세기

strawberry 에는 알파벳 'r' 이 몇 개인가? 근거와 함께 답해 줘

Claude-3-Sonnet Poe

'strawberry'에는 알파벳 'r'

근거:

1. 'strawberry'라는 단어
2. 구체적으로는 'strawbe
3. 따라서 'strawberry'에

"Strawberry"라는 단어에는 알파벳 'r'이 **3개** 있습니다.

근거: 단어를 분석하면, 'strawberry'는 다음과 같이 나눌 수 있습니다:

- s
- t
- r
- a
- w
- b
- e
- r
- r
- y

따라서, 'r'이 3번 등장합니다.

strawberry 단어에는 알파벳 'r'이 2개 있습니다.

니다.

벳을 세어보면 총 10개의 알파벳으로 이루어져 있습니다.

와 네 번째 알파벳에 위치하고 있습니다.

는 알파벳 'r'이 2개 있습니다.

GPT-4o-Mini Poe

단어 "strawberry"

근거:

- "strawberry"를
  - s, t, r, a, w
- 여기서 'r'이 두

따라서, "strawberry

Poe

알파벳 'r' 이 **두 개** 있습니다.

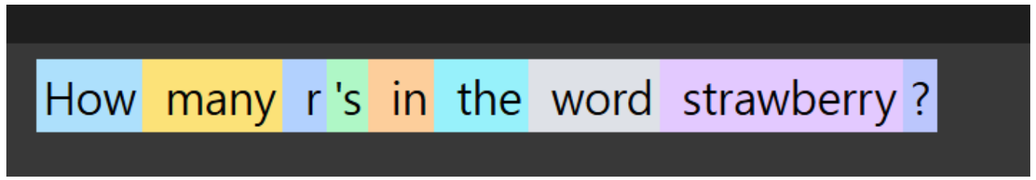
다음과 같습니다:

라는 단어를 씁니다.
른쪽으로 글자를 보면서 'r' 을 찾습니다.
동그라미를 칩니다.
에는 동그라미 친 'r' 이 두 개 있습니다.

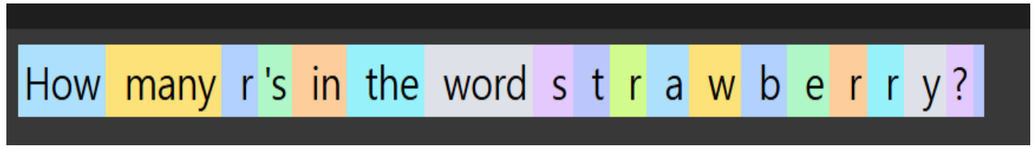
rry' 에는 'r' 이 두 개 있습니다.

토큰화에 의한 구조적 약점

```
prompt ==  How many r's in the word strawberry?
That's an easy one! There are 2 R's in the word "strawberry".None
```

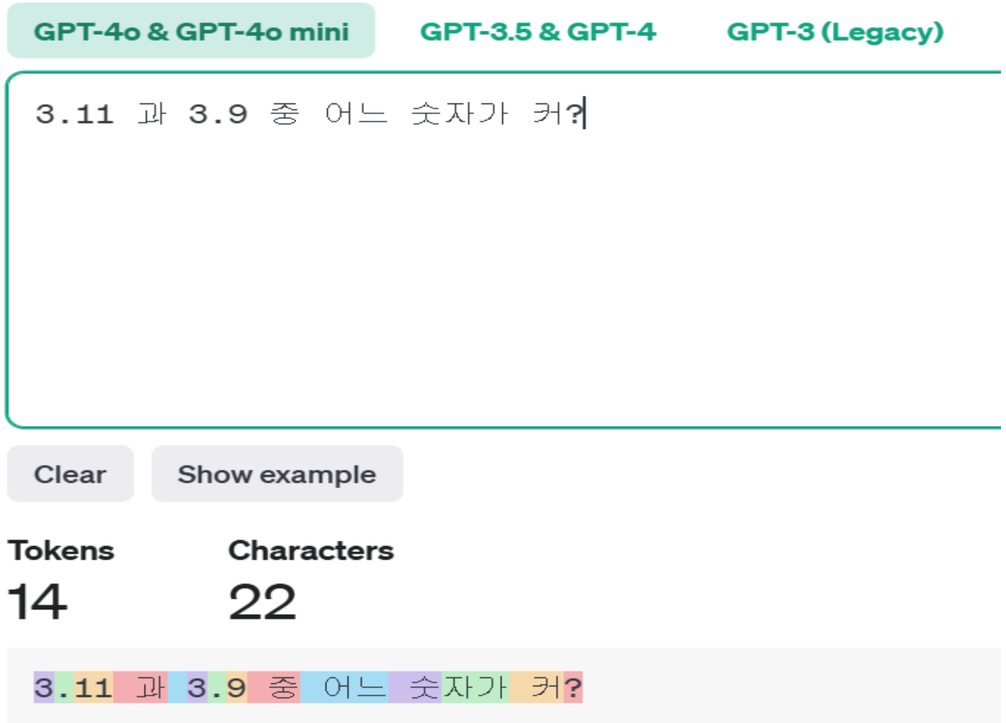



```
prompt ==  How many r's in the word s t r a w b e r r y?
There are 3 R's in the word "strawberry".None
```

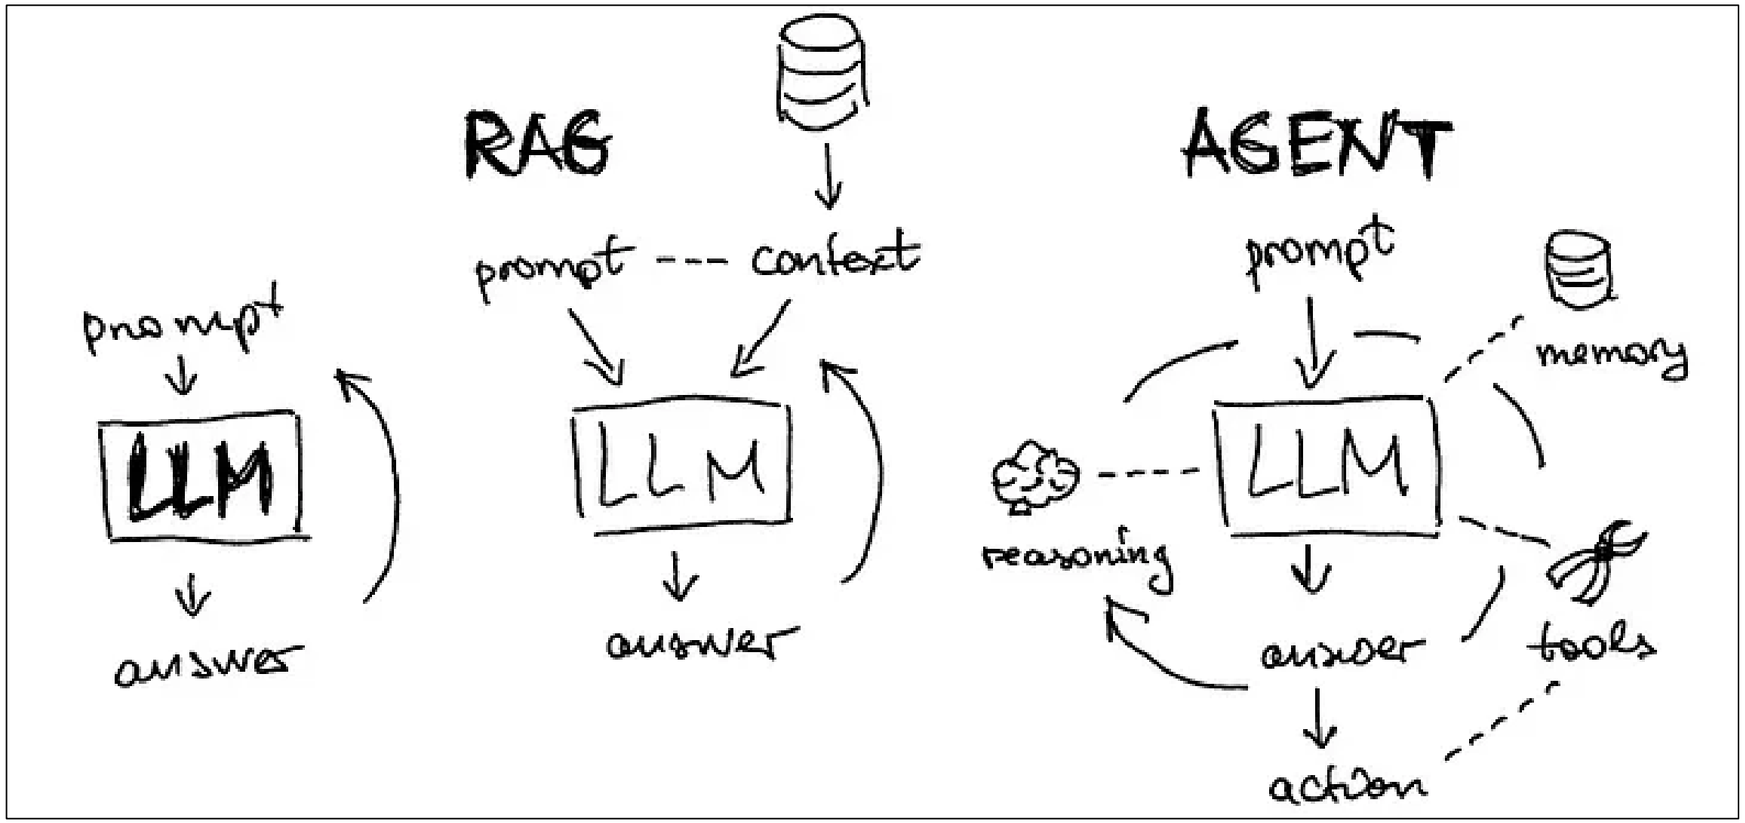


3.11 과 3.9 중 어느 숫자가 커?

3.11이 3.9보다 큽니다. 소수점 첫 번째 자리까지 같지만, 두 번째 자리에서 1이 9보다 크므로 3.11이 더 큰 숫자입니다.



AI Agent 의 등장



- 다양한 Tool을 장착한 자율적(Autonomous) 판단을 하는 에이전트(Agent}
- 데이터 검색 뿐 아니라, 생성/변경/삭제 기능 추가

출처 : https://ai.meta.com/blog/retrieval-augmented-generation-streamlining-the-creation-of-intelligent-natural-language-processing-models/

추론 에이전트에 의한 토큰 사용량 증대



출처 : https://www.youtube.com/watch?v=TeGsFFNqRLA

증가하는 추론(Inference)를 위한 컴퓨팅 자원

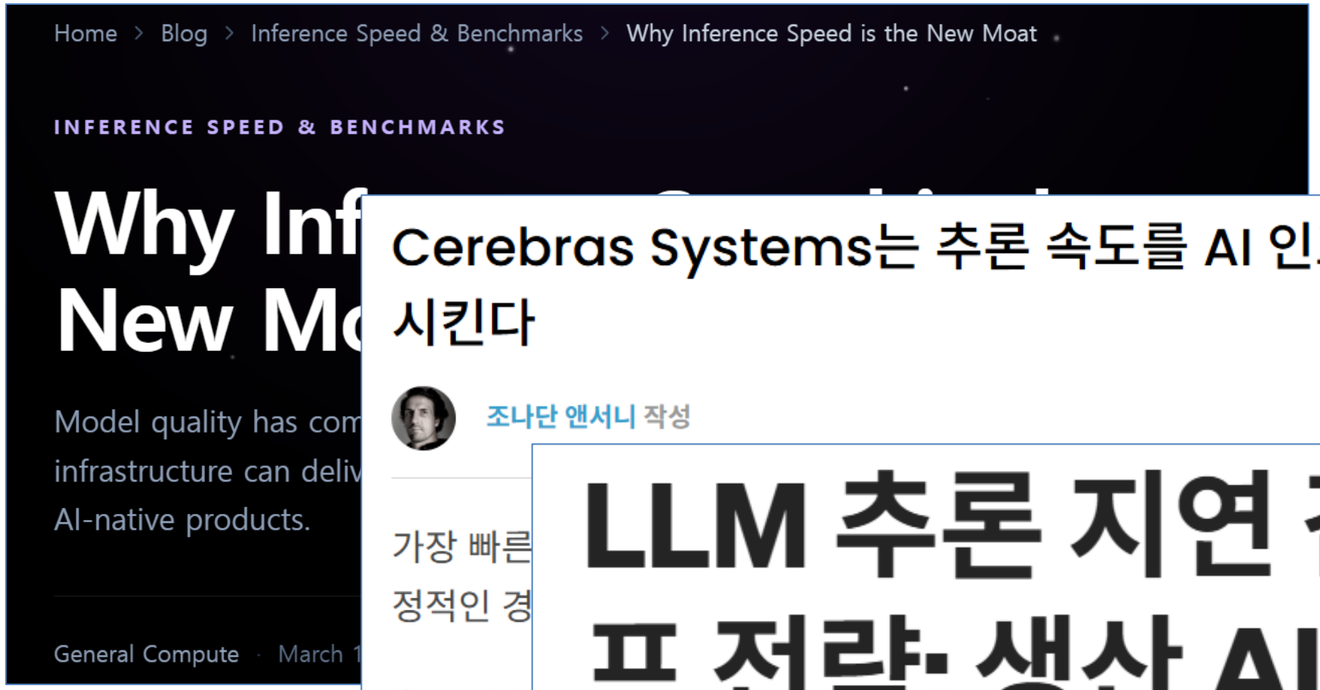


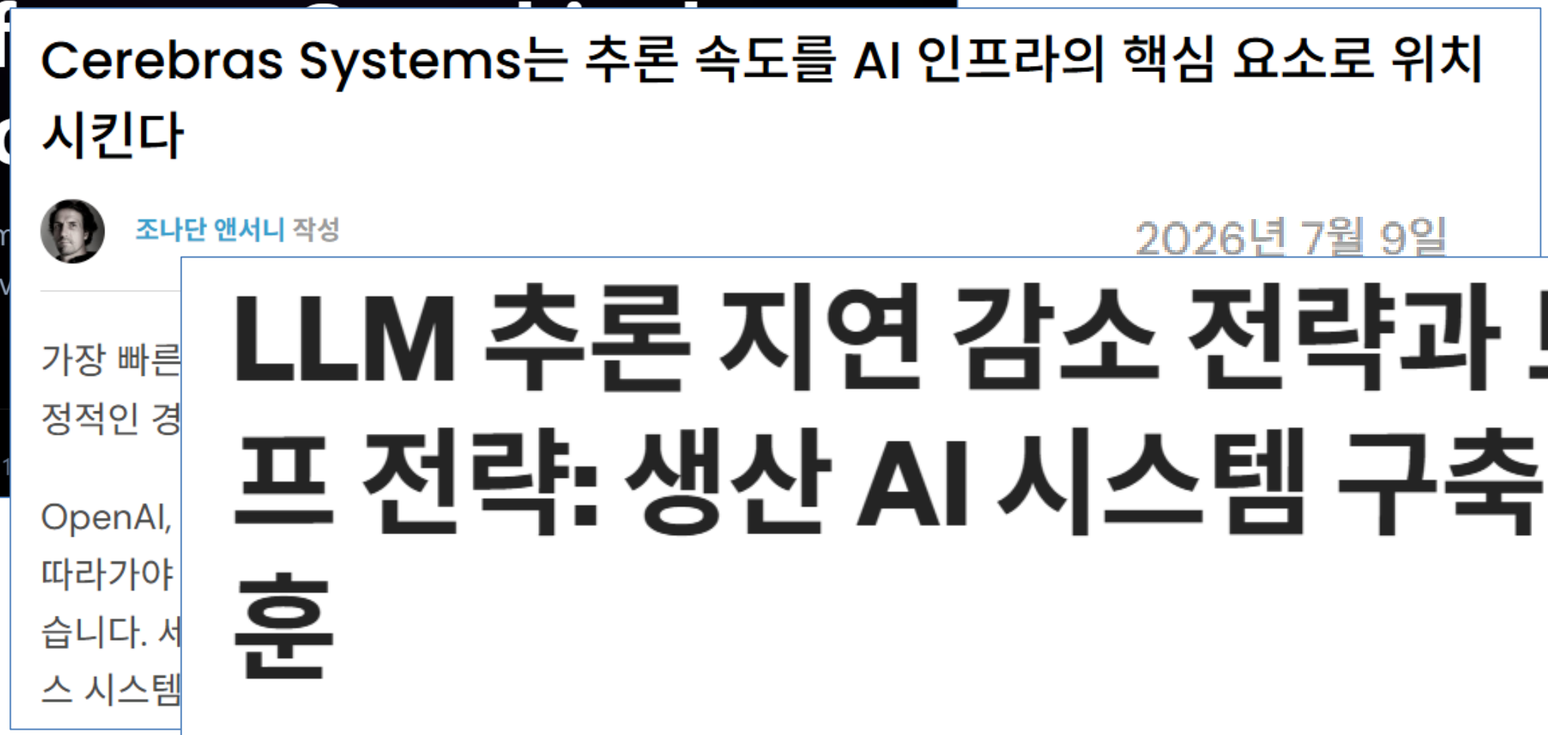
효율적 추론(Inference) : 적은 자원으로 빠른 추론



출처 : https://www.youtube.com/watch?v=TeGsFFNqRLA

추론 속도(Inference Speed) 경쟁 시대







토큰 가격 (Token Price)

GPT-5.5

코딩과 전문 작업을 지원하는 새로운 차원의 인텔리전스

가격

입력:
US$5.00/토큰 100만 개

캐시된
US$0.5

출력:
US$30.

GPT-5.4

코딩과 전문 작업에 최적화된 합리적 모델

가격

입력:
US$2.50/토큰 100만 개

GPT-5.4 mini

지금까지 공개된 소형 모델 가운데 코딩, 컴퓨터 사용, 서브에이전트 작업에서 가장 강력한 성능을 제공하는 모델

가격

입력:
US$0.75/토큰 100만 개

[글로벌] 오픈AI, '토큰' 가격 대폭 인하 검토...앤트로픽과 가격 전쟁 예고

허준 편집장 | 승인 2026.06.13 09:30

가 가

출처 : [What Is the ChatGPT Token Limit and Can You Exceed It? (makeuseof.com)]

API 토큰 가격 (Token Price)

2026 Aug 15

Flagship models

Our latest models

Prices per 1M tokens.

Standard | Batch | Flex | Fast mode

>272K input tokens

Model	Short context Input	Cached input	Cache writes	Output	Long context Input	Cached input	Cache writes	Output
gpt-5.6-sol	$5.00	$0.50	$6.25	$30.00	$10.00	$1.00	$12.50	$45.00
gpt-5.6-terra	$2.00	$0.20	$2.50	$12.00	$4.00	$0.40	$5.00	$18.00
gpt-5.6-luna	$0.20	$0.02	$0.25	$1.20	$0.40	$0.04	$0.50	$1.80
gpt-5.5	$5.00	$0.50	-	$30.00	$10.00	$1.00	-	$45.00
gpt-5.5-pro	$30.00	-	-	$180.00	$60.00	-	-	$270.0
gpt-5.4	$2.50	$0.25	-	$15.00	$5.00	$0.50	-	$22.50
gpt-5.4-mini	$0.75	$0.075	-	$4.50	-	-	-	-
gpt-5.4-nano	$0.20	$0.02	-	$1.25	-	-	-	-
gpt-5.4-pro	$30.00	-	-	$180.00	$60.00	-	-	$270.0

출처 : Pricing | OpenAI API

입출력 제한 : 토큰 제한 해제 - 책 전체 요약 가능

300쪽짜리 책도 몇초만에 요약 … 자비 없이 치고나가는 오픈AI

이덕주 기자
입력 : 2023-11-07 17:29:32
수정 : 2023-11-07 23:17:08

오픈AI는 챗GPT를 공개한 지 약 1년이 된 6일(현지시간) '오픈AI 데브데이(DevDay)'에서 후발 주자와 격차를 더욱 벌리기 위한 전략을 여실히 드러냈다.

전 세계에서 개발자 수백 명이 집결한 가운데 가장 큰 주목을 받은 것은 '맞춤형 챗GPT'였다. 그동안 챗GPT와 같은 AI 챗봇을 개인 맞춤형으로 개발하려는 [illegible] 수 있다고 설명했다. GPT 프로 [illegible] 질문하자 그의 원 [illegible]

기존 챗GPT도 [illegible] 하는 비전 능력, 이미지를 그리는 달리(DALLE)-3 능력, 텍스트를 음성으로 바꾸는 TTS 기능을 기존으로 업데이트 했다. TTS에서는 총 6개 목소리를 제공한다.

한편 이날 행사에는 사티아 나델라 마이크로소프트(MS) CEO가 직접 참석해 오픈AI와의 파트너십이 든든함을 과시했다. MS는 오픈AI 주요 투자자인데, 오픈AI의 AI 서비스를 자신들의 클라우드 인프라스트럭처를 통해 고객들에게 제공하고 있다. MS는 오픈AI의 AI로 만든 서비스를 365, 윈도 등에 코파일럿이라는 이름으로 서비스하고 있다.

나델라 CEO는 "나는 인프라 비즈니스를 30년 넘게 해왔는데 오픈AI와의 파트너십으로 MS 애저도 많은 변화를 했다"면서 "두 회사의 협력은 개발자들이 새로운 것을 만드는 데 큰 도움을 줄 것"이라고 설명했다.

출처 : https://m.mk.co.kr/news/it/10868530

에이전트 시대
토큰 생성 비용과 속도 경쟁 ~~

더 똑똑해진 GPT-4 터보
올해 4월까지 정보 수록하고
·생성 기능 탑재

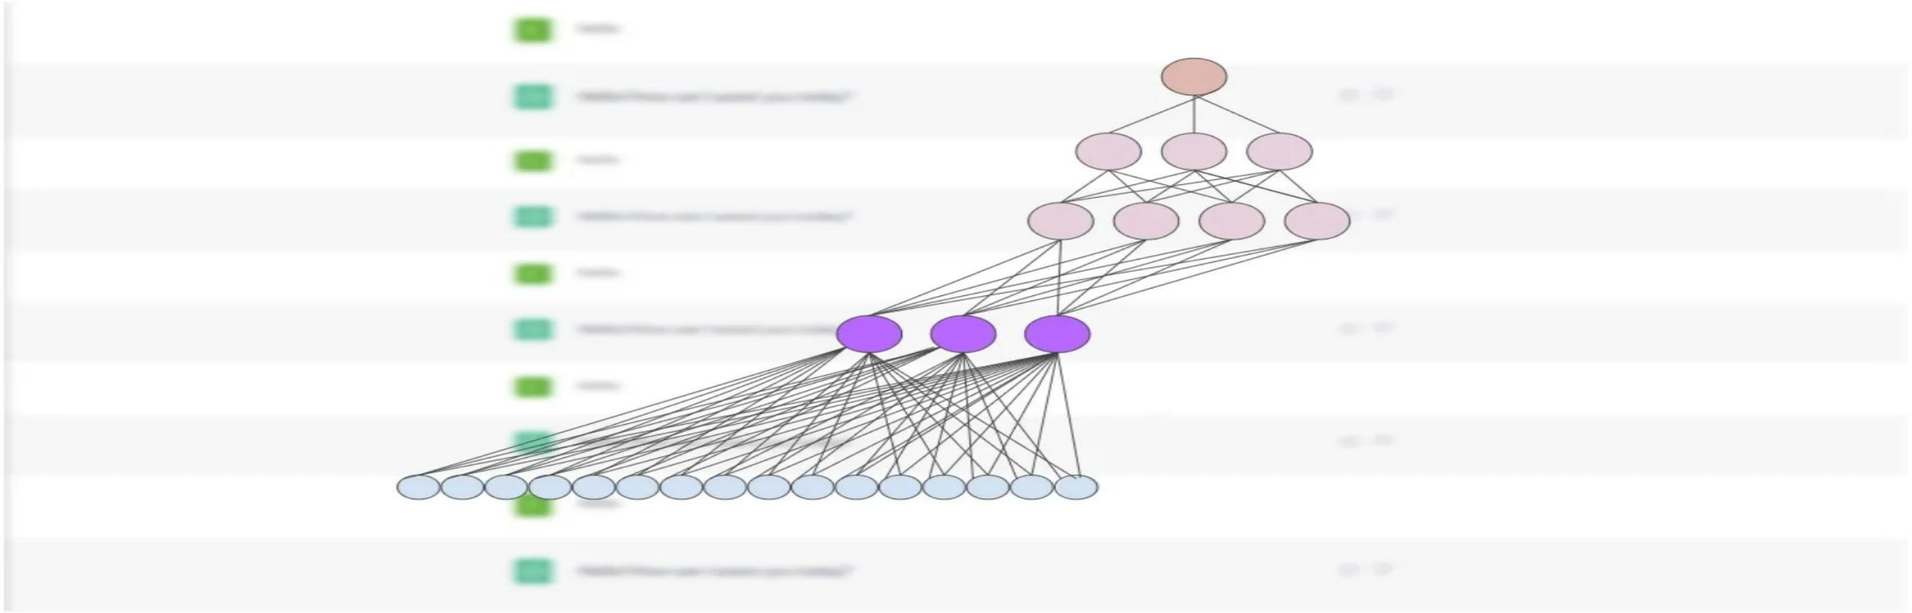
축 어떻게
만들어 올리면
애플처럼 앱스토어서 AI 거래

구글·메타 주춤할때 질주
스타트업 진입장벽 높아져
'사다리 걷어차기' 평가도

ChatGPT의 숨겨진 무기 – 임베딩(Embedding)

Embeddings: ChatGPT's Secret Weapon

Embeddings, and how they help ChatGPT predict the next word



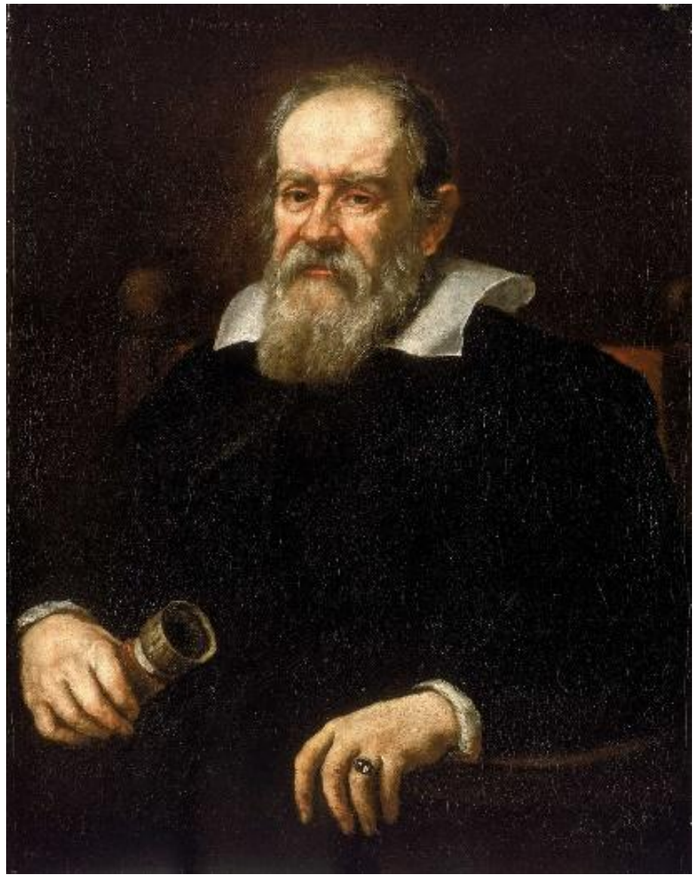
(image by author)

- 컴퓨터가 다루는(다룰 수 있는) 것은 숫자
- 인공지능은 숫자를 예측한다.

출처 : Embeddings: ChatGPT's Secret Weapon | by Emma Boudreau | Mar, 2023 | Towards Data Science

과학적 접근의 기초 ➔ 수치화 (**벡터화**)





셀 수 있는 모든 것을 세고, 잴 수 있는 모든 것을 재어라.

그리고 잴 수 없는 것은 잴 수 있게 만들어라

– 갈릴레오

https://m.blog.naver.com/PostView.nhn?blogId=cjcityblog&logNo=221085979515&proxyReferer=https:%2F%2Fwww.google.com%2F

텍스트의 수치화 : 훈련에 의한 임베딩 – 딥러닝 방식

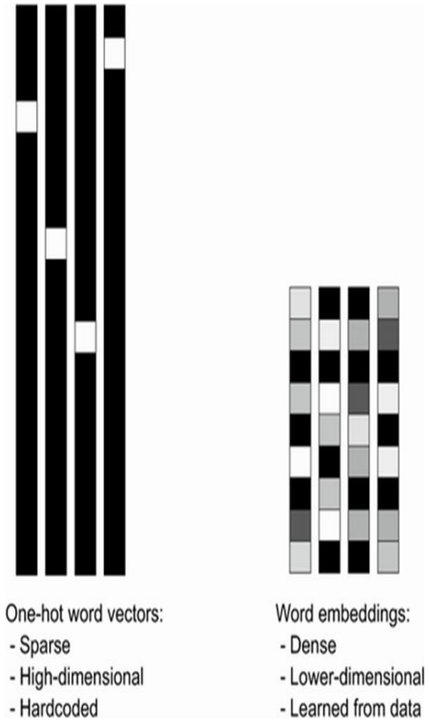
- **빈도 기반 분석의 문제점**
  - 단어 표현에 큰 벡터가 필요 (One-Hot encoding)
  - 언어의 의미를 담지 못한 수치화

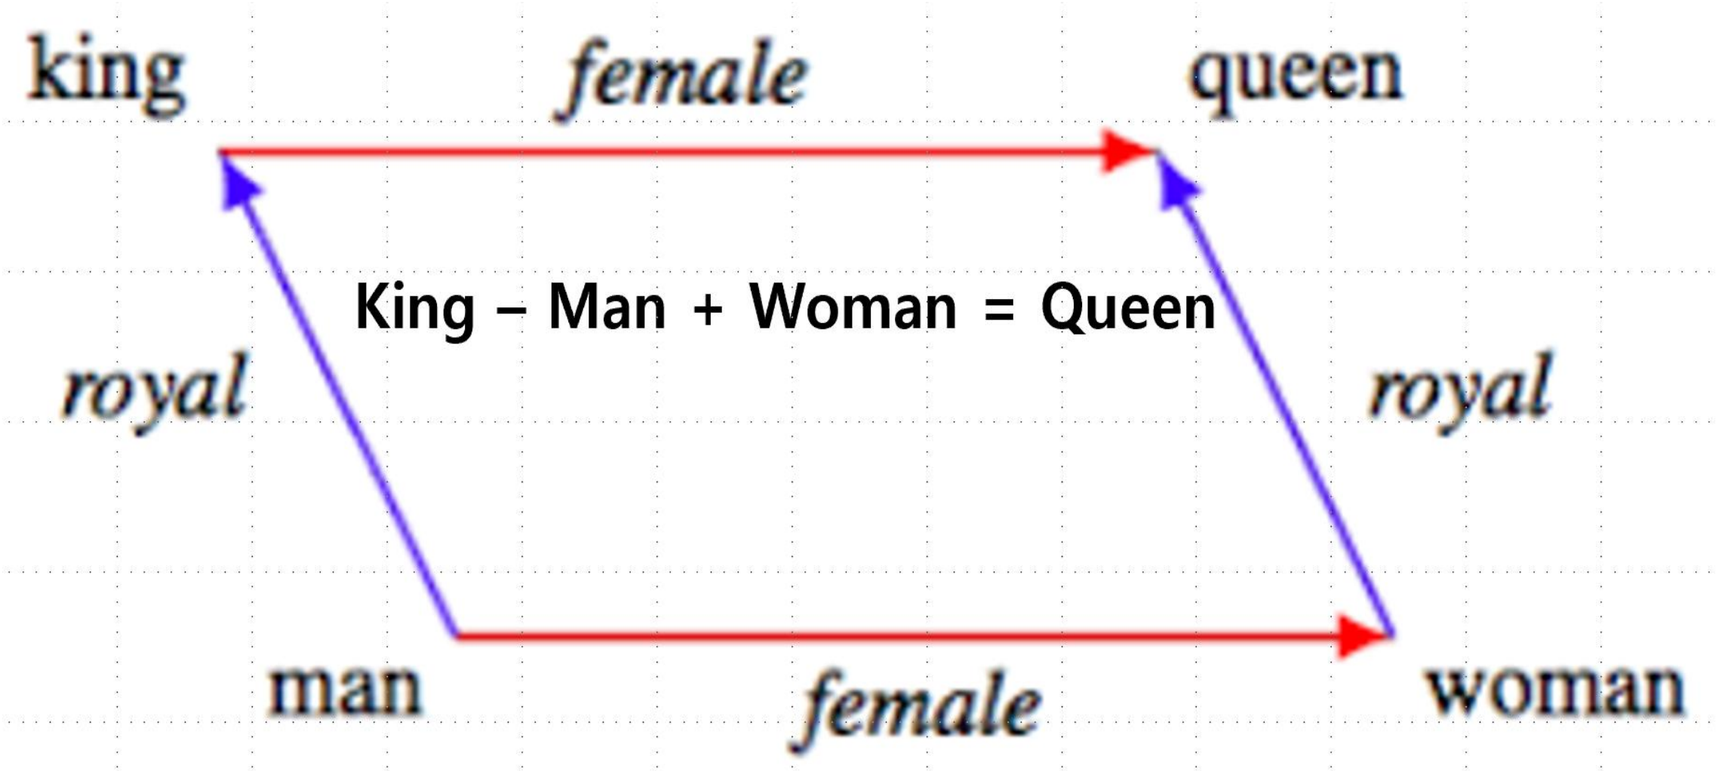
- **언어(단어)의 의미를 수치에 담을 수 있을까?**
  - 문장은 의미를 갖는다.
  - 같은 문장 내의 단어는 하나의 의미를 전달한다.
  - 문장 내의 단어를 가까운 위치에 존재하게 만들자.

➔ **Word2Vec**



임베딩(Embedding) 예제 Demo : Word2Vec





- 언어의 벡터화
  - ✓ Count 기반, Tf-Idf …. ➔ 통계적 방식
  - ✓ 훈련에 의한 생성 ➔ 딥러닝 (특성 추출 : Feature Extraction)

이미지 출처 Deep Learning with Python, Second Edition (manning.com)

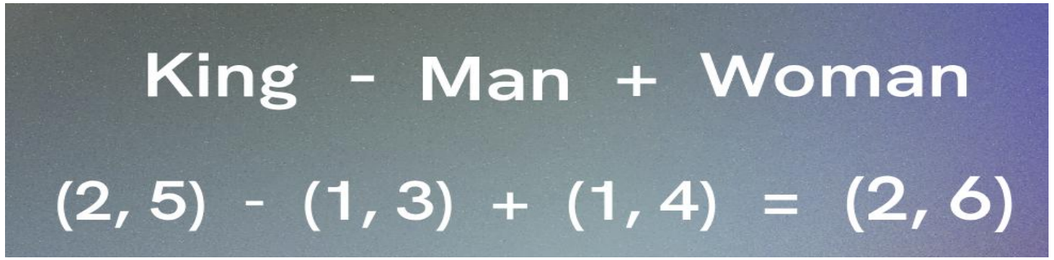
Word2Vec ➔ 단어의 개념 수치화

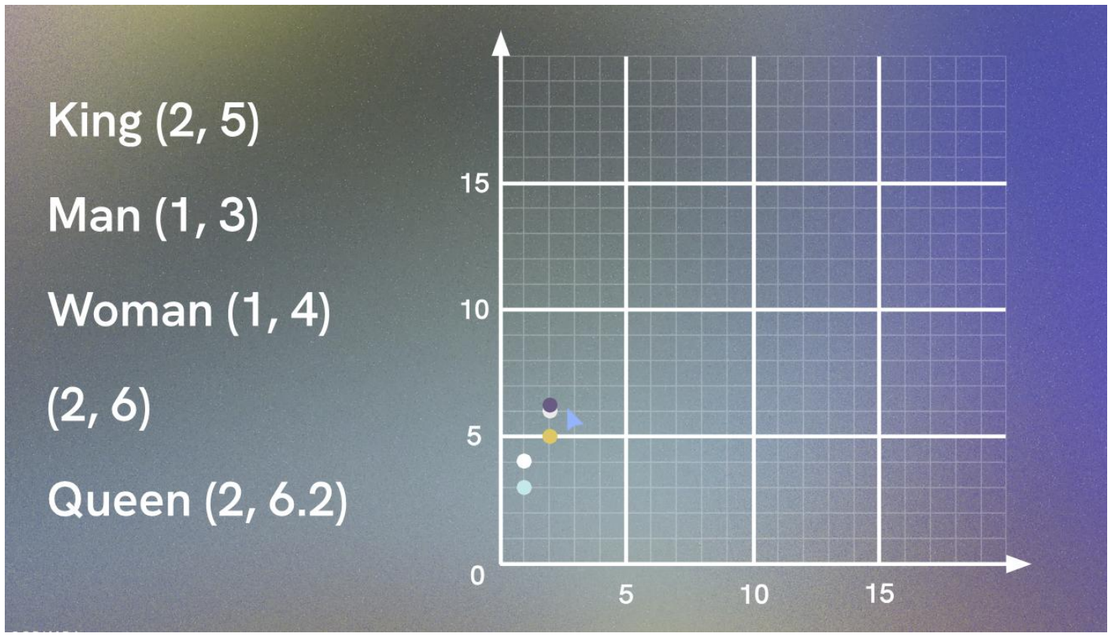
```
model.most_similar(positive=['king','woman'], negative=['man'],topn=10)
Out[12]:
[('queen', 0.7118192911148071),
 ('monarch', 0.6189674139022827),
 ('princess', 0.5902431607246399),
 ('crown_prince', 0.5499460697174072),
 ('prince', 0.5377321243286133),
 ('kings', 0.5236844420433044),
 ('Queen_Consort', 0.5235945582389832),
 ('queens', 0.5181134343147278),
 ('sultan', 0.5098593235015869),
 ('monarchy', 0.5087411999702454)]
```

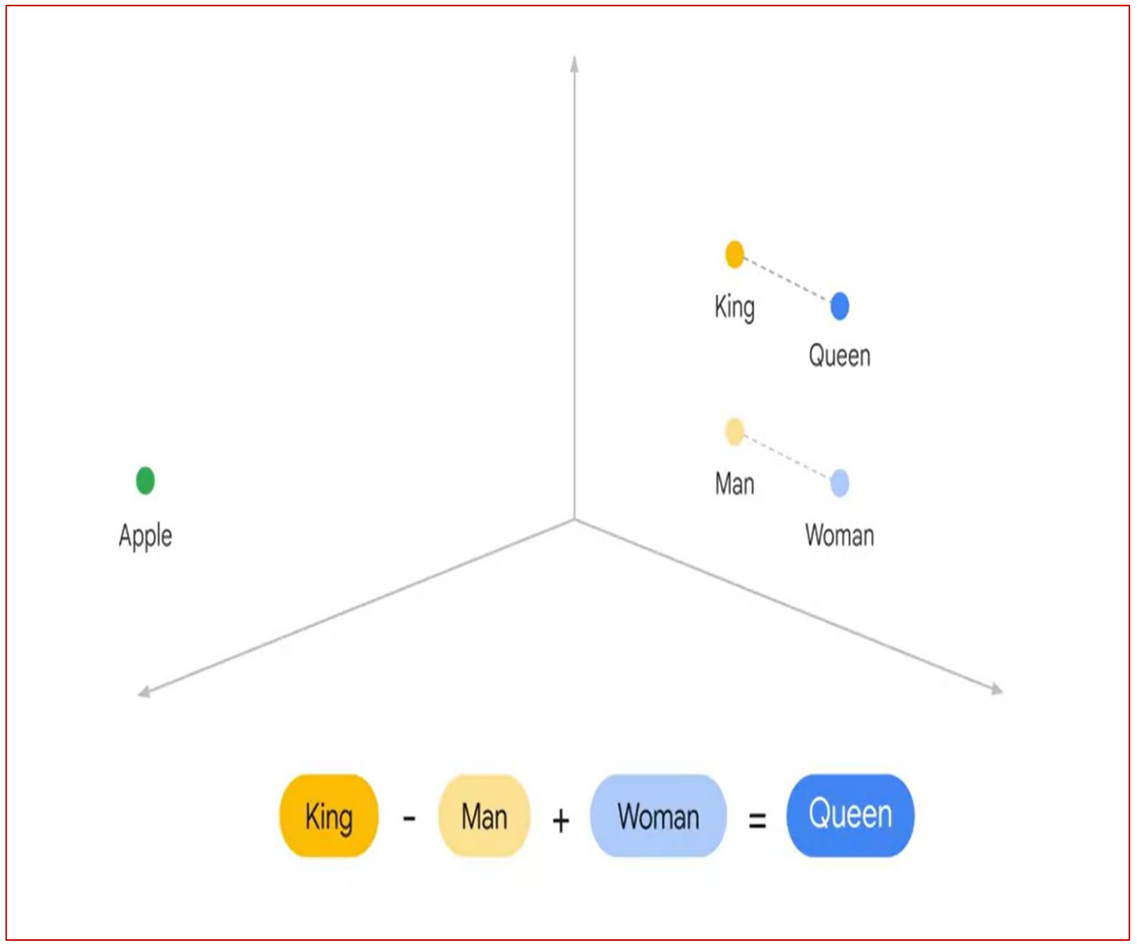
훈련된 문장에서 거리를 배운다

➔ 영역 별 거리도 만든다

임베딩(Embedding) 예 : Word2Vec



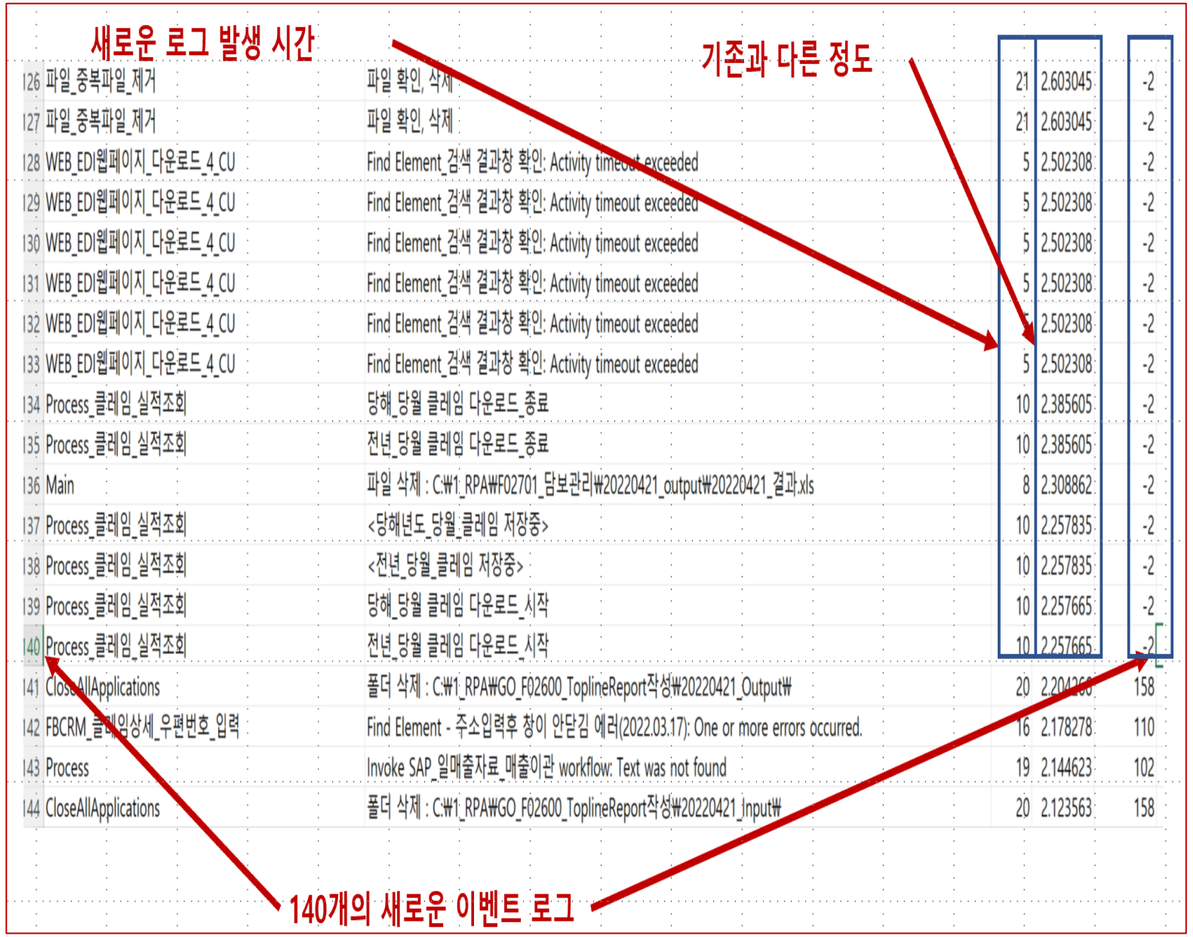




이미지 출처 Deep Learning with Python, Second Edition (manning.com)

언어 잠재 공간의 활용 – 로그 군집화

	A	I	P
20817	Main	Processing Transaction Number: 30	169
20818	Main	Processing Transaction Number: 31	169
20819	Main	Processing Transaction Number: 32	169
20820	Main	Processing Transaction Number: 33	169
20821	Main	Processing Transaction Number: 34	169
20822	Main	Processing Transaction Number: 35	169
20823	Main	Processing Transaction Number: 36	169
20824	Main	Processing Transaction Number: 0	169
20825	Main	Processing Transaction Number: 1	169
20826	Main	Processing Transaction Number: 2	169
20827	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20828	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20829	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20830	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20831	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20832	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20833	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20834	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20835	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20836	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20837	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20838	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20839	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20840	2. Init_엑셀_신규발주확인	2. Init_엑셀_신규발주확인_시작	170
20841	SAP_일매출자료_3_매출정산확정처리(ZSDP1003)	SAP_일매출자료_매출정산확정처리(ZSDP1003) 종료	171



126	파일_중복파일_제거	파일 확인, 삭제	21	2.603045	-2
127	파일_중복파일_제거	파일 확인, 삭제	21	2.603045	-2
128	WEB_EDI웹페이지_다운로드_4_CU	Find Element_검색 결과창 확인: Activity timeout exceeded	5	2.502308	-2
129	WEB_EDI웹페이지_다운로드_4_CU	Find Element_검색 결과창 확인: Activity timeout exceeded	5	2.502308	-2
130	WEB_EDI웹페이지_다운로드_4_CU	Find Element_검색 결과창 확인: Activity timeout exceeded	5	2.502308	-2
131	WEB_EDI웹페이지_다운로드_4_CU	Find Element_검색 결과창 확인: Activity timeout exceeded	5	2.502308	-2
132	WEB_EDI웹페이지_다운로드_4_CU	Find Element_검색 결과창 확인: Activity timeout exceeded	5	2.502308	-2
133	WEB_EDI웹페이지_다운로드_4_CU	Find Element_검색 결과창 확인: Activity timeout exceeded	5	2.502308	-2
134	Process_클레임_실적조회	당해_당월 클레임 다운로드_종료	10	2.385605	-2
135	Process_클레임_실적조회	전년_당월 클레임 다운로드_종료	10	2.385605	-2
136	Main	파일 삭제 : C:₩1_RPA₩F02701_담보관리₩20220421_output₩20220421_결과.xls	8	2.308862	-2
137	Process_클레임_실적조회	<당해년도_당월_클레임 저장중>	10	2.257835	-2
138	Process_클레임_실적조회	<전년_당월_클레임 저장중>	10	2.257835	-2
139	Process_클레임_실적조회	당해_당월 클레임 다운로드_시작	10	2.257665	-2
140	Process_클레임_실적조회	전년_당월 클레임 다운로드_시작	10	2.257665	-2
141	CloseAllApplications	폴더 삭제 : C:₩1_RPA₩GO_F02600_ToplineReport작성₩20220421_Output₩	20	2.204366	158
142	FBCRM_클레임상세_우편번호_입력	Find Element - 주소입력후 창이 안닫김 에러(2022.03.17): One or more errors occurred.	16	2.178278	110
143	Process	Invoke SAP_일매출자료_매출이관 workflow: Text was not found	19	2.144623	102
144	CloseAllApplications	폴더 삭제 : C:₩1_RPA₩GO_F02600_ToplineReport작성₩20220421_Input₩	20	2.123563	158

- 유사한 로그 군집 ➔ 로그 분석 시간 단축
- 유사하지 않은 로그 탐색 ➔ 새로 발생한 로그 통지

언어 잠재 공간의 활용 – 로그 군집화

관인생략

출원번호통지서

출원일자	2022.09.14
특기사항	심사청구(유) 공개신청(무)
출원번호	10-2022-0115899 (접수번호 1-1-2022-0964895-21) (DAS접근코드0402)
출원인 명칭	위데이터랩 주식회사(1-2018-080107-0)
대리인 성명	양영필(9-1998-000652-2)
발명자 성명	강승우
발명의 명칭	잠재 공간 기반 로그 이벤트 모니터링 시스템 및 방법

특 허 청 장



특허증

CERTIFICATE OF PATENT

특허 Patent Number 제 10-2787233 호

출원번호 Application Number 제 10-2022-0154001 호

출원일 Filing Date 2022년 11월 16일

등록일 Registration Date 2025년 03월 21일

발명의 명칭 Title of the Invention

잠재 공간 기반 로그 모니터링 처리 시스템 및 방법

특허권자 Patentee

위데이터랩 주식회사(110111-*******)

서울특별시 종로구 삼일대로 457, 1303호 (경운동, 수운회관)

발명자 Inventor

강승우(670710-*******)

서울시 용산구 한남동 726-353 (202)

위의 발명은 「특허법」에 따라 특허원부에 등록되었음을 증명합니다.

This is to certify that, in accordance with the Patent Act, a patent for the invention has been registered at the Korean Intellectual Property Office.

2025년 03월 21일

특허청

Korean Intellectual Property Office

QR코드로 현재기준 등록사항을 확인하세요

특허청장

COMMISSIONER, KOREAN INTELLECTUAL PROPERTY OFFICE

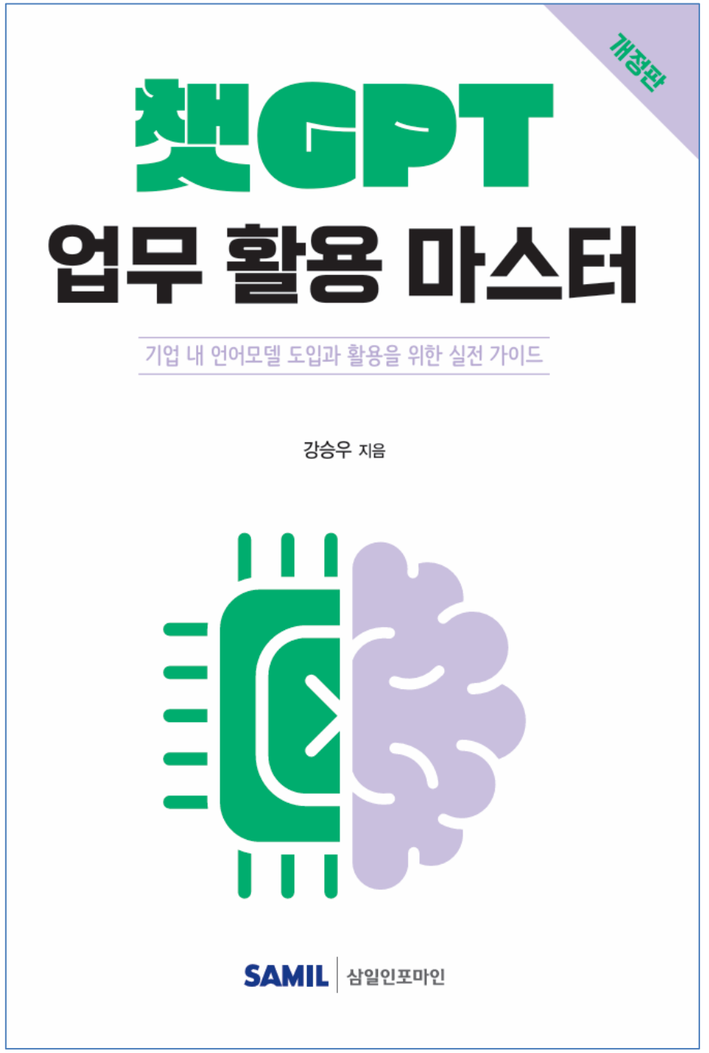
김완기

요 약

요약

- 사회 기반 시설로 자리잡는 AI
  - ✓ 문서 작성, 번역, 요약, ….
  - ✓ 확대되는 활용 범위
    - 도면 인식, 제약, 학술
    - 법률, 예술, …

- ChatGPT 기반 기술
  - ✓ 자연어 처리(NLP) = 자연어 이해(NLU) + 자연어 생성(NLG)
  - ✓ 임베딩(Embeddings) : 의미를 담은 숫자
  - ✓ 토큰(Token) : 언어 AI 모델의 최소 처리 단위



WeDataLab

감사합니다.

© Copyrights 2026. Wedatalab All Rights Reserved.